



Zadání diplomové práce

Název:	Automatická detekce pohybových artefaktů v EKG signálu z nositelného snímače pomocí metod umělé inteligence
Student:	Bc. Veronika Kalousková
Vedoucí:	doc. Ing. Pavel Smrčka, Ph.D.
Studijní program:	Informatika
Obor / specializace:	Znalostní inženýrství
Katedra:	Katedra aplikované matematiky
Platnost zadání:	do konce letního semestru 2024/2025

Pokyny pro vypracování

Automatické rozpoznání nehodnotitelných úseků v EKG signálu je jedním z klíčových problémů při dlouhodobé terénní monitoraci pomocí nositelné elektroniky.

- Provedte a přehledně zpracujte rešerši metod pro detekci pohybových, svalových atd. artefaktů v EKG signálu.
- Navrhněte a realizujte sérii řízených laboratorních experimentů při simulované fyzické zátěži s cílem seznámit se s problematikou pohybových artefaktů v reálném EKG signálu měřením za pomoci poskytnutého nositelného EKG, vybaveného vizualizačním a záznamovým SW. Vytvořte anotovaný katalog digitalizovaných EKG signálů při různých typech a stupních zátěže, obsahující charakteristické pohybové artefakty (klid, stoj, leh, chůze a běh na chodícím pásu apod.). Jako svodový systém volte 1 bipolární kanál s povrchovými EKG elektrodami umístěnými na hrudníku (pozice například V3-V3R až V5-V5R). Experimenty provedte s několika dodanými typy elektrod (klasické jednorázové gelové Ag-AgCl elektrody, plošné suché elektrody z chromnickové oceli, suché nositelné textilní elektrody na bázi vodivé tkaniny).
- Navrhněte a implementujte algoritmus pro off-line automatické rozpoznání pohybových artefaktů v EKG signálu při jednotlivých typech a stupních zátěže z realizované série experimentů, založený na kombinaci klasické číslicové filtrace a použití neuronových sítí vhodné topologie, natrénovaných na vytvořeném katalogu s charakteristickými průběhy EKG signálu s pohybovými artefakty při jednotlivých typech fyzické zátěže.
- Ověřte a zhodnoťte kvalitu klasifikace, tj. schopnost natrénované neuronové sítě



rozpoznat nehodnotitelné segmenty záznamu, případně rozpoznat na základě klasifikace artefaktů jednotlivé typy zátěže.

- Postup páce, včetně použité metody a vytvořeného software podrobně zdokumentujte a diskutujte praktickou použitelnost metody a její možná budoucí vylepšení.



Diplomová práca

**AUTOMATICKÁ DETEKCIA POHYBOVÝCH
ARTEFAKTOV V EKG SIGNÁLI
Z NOSITEĽNÉHO SNÍMAČA POMOCOU
METÓD UMELEJ INTELIGENCIE**

Bc. Veronika Kalousková

Fakulta informačných technologií
Katedra aplikovanej matematiky
Vedúci: doc. Ing. Pavel Smrčka, Ph.D.
9. mája 2024

České vysoké učení technické v Praze
Fakulta informačních technologií

© 2024 Bc. Veronika Kalousková. Všetky práva vyhradené.

Táto práca vznikla ako školské dielo na FIT ČVUT v Prahe. Práca je chránená medzinárodnými predpismi a zmluvami o autorskom práve a právach súvisiacich s autorským právom. Na jej využitie, s výnimkou bezplatných zákonných licencii, je nutný súhlas autora.

Odkaz na túto prácu: Kalousková Veronika. *Automatická detekcia pohybových artefaktov v EKG signáli z nositeľného snímača pomocou metód umelej inteligencie*. Diplomová práca. České vysoké učení technické v Praze, Fakulta informačních technologií, 2024.

Obsah

Pod'akovanie	vi
Vyhlásenie	vii
Abstrakt	viii
Zoznam skratiek	ix
Úvod	1
1 Analýza problému	2
1.1 Stavba a funkcia srdca	2
1.1.1 Akčný potenciál srdcovej membrány	2
1.2 Elektrokardiografia	3
1.2.1 Elektródy a zvody	4
1.2.2 Einthovenove končatinové zvody	4
1.2.3 Goldbergove končatinové zvody	5
1.2.4 Wilsonove hrudné zvody	6
1.3 Typy povrchových elektród	6
1.3.1 Argentchloridové elektródy	7
1.3.2 Textilné elektródy	7
1.4 EKG krvka	8
1.4.1 Genéza signálu	8
1.4.2 Elektrická os srdečnej	9
1.4.3 Interpretácia EKG	10
1.5 Artefakty v EKG	11
1.5.1 Kolísanie izoelektrickej línie	11
1.5.2 Sieťové rušenie	12
1.5.3 Pohybové artefakty	13
1.6 Automatická detekcia artefaktov v EKG	14
1.6.1 Tradičné metódy spracovania signálu	14
1.6.2 Umelé neurónové siete (ANN)	15
1.6.3 Konvolučné neurónové siete (CNN)	16
1.6.4 Rekurentné neurónové siete (RNN)	17
1.6.5 Support vector machines (SVM)	18
1.7 Vyhodnotenie klasifikácie do viacerých tried	19
1.7.1 Matica zámen	19
1.7.2 Accuracy	20
1.7.3 Recall	21
1.7.4 Precision	21
1.7.5 F1 Score	21

2 Metodika experimentu	22
2.1 Popis subjektov	22
2.2 Použitý hardware	23
2.3 Použitý software	24
2.3.1 Vizualizácia a záznam EKG	24
2.3.2 Manuálna anotácia dát	24
2.4 Použité elektródy	26
2.5 Priebeh experimentu	27
3 Dátová sada	28
3.1 Anotácia dátovej sady	28
3.1.1 Artefakt kategórie 1	29
3.1.2 Artefakt kategórie 2	30
3.1.3 Artefakt kategórie 3	30
3.1.4 Artefakt kategórie 4	31
3.2 Štruktúra dát	32
3.3 Zastúpenie tried	33
3.4 Predspracovanie dát	34
4 Výsledky	35
4.1 Vyhodnotenie typu elektród	35
4.2 Klasifikácia pohybových aktivít	37
4.2.1 Model	37
4.2.2 Vyhodnotenie klasifikácie	39
4.3 Klasifikácia pohybových artefaktov	40
4.3.1 Model	40
4.3.2 Vyhodnotenie klasifikácie	43
5 Diskusia	46
6 Záver	48
A Informovaný súhlas	50
B Dotazník	53
Obsah príloh	59

Zoznam obrázkov

1.1	Akčný potenciál srdcovej membrány [5].	3
1.2	Einthovenove končatinové zvody [8].	5
1.3	Goldbergove končatinové zvody [8].	5
1.4	Wilsonove hrudné zvody [9].	6
1.5	Súvis akčného potenciálu srdcovej membrány a EKG krvky [5].	9
1.6	Elektrická os srdečná [23].	10
1.7	Sínusový rytmus [26].	11
1.8	Kolísanie izoelektrickej línie [26].	11
1.9	Sieťové rušenie [26].	12
1.10	Pohybový artefakt [26].	13
1.11	Konvolúcia matice s kernelom [40].	16
1.12	Rozvinutie rekurentnej neurónovej siete v čase [47].	18
1.13	Optimálna separačná nadrovina [51].	19
1.14	Matica zámen pre klasifikáciu do viacerých tried.	20
2.1	Vývojový modul s obvodom AD8232 [56].	23
2.2	Software na vizualizáciu a záznam EKG.	24
2.3	Grafické rozhranie na manuálnu anotáciu EKG dát.	25
2.4	Hrudný pás s elektródami z nerezovej ocele a textilnými elektródami.	26
3.1	Segmenty patriace do kategórie 1.	29
3.2	Segment patriaci do kategórie 2.	30
3.3	Segment patriaci do kategórie 3.	30
3.4	Segmenty patriace do kategórie 4.	31
3.5	Počty segmentov podľa typu artefaktu.	33
3.6	Počty segmentov podľa typu aktivity.	34
3.7	Počty segmentov podľa typu elektródy.	34
4.1	Podiel artefaktov podľa typu elektródy.	36
4.2	Výsledný model pre klasifikáciu pohybových aktivít.	38
4.3	Matica zámen pre klasifikáciu pohybových aktivít.	39
4.4	Výsledný model pre klasifikáciu pohybových artefaktov.	41
4.5	Priebeh vývoju straty a presnosti modelu pred použitím plánovania <i>learning rate</i>	42
4.6	Priebeh vývoju straty a presnosti modelu po použití plánovania <i>learning rate</i>	42
4.7	Matica zámen pre klasifikáciu pohybových artefaktov.	43
4.8	Matica zámen pre klasifikáciu pohybových artefaktov po zlúčení tried 2 a 3.	44
4.9	Matica zámen pre klasifikáciu čitateľnosti srdečného rytmu.	45

Zoznam tabuliek

2.1	Prehľad subjektov experimentu.	23
2.2	Poradie pohybových aktivít.	27
3.1	Súbor s EKG záznamom.	32
3.2	Kódovanie pohybovej aktivity.	32
3.3	Kódovanie typu elektród.	32
3.4	Výstupný súbor s anotovanými dátami.	33
4.1	Podiel artefaktov podľa typu aktivity a typu elektródy.	35
4.2	<i>Precision</i> a <i>recall</i> pre klasifikáciu pohybových artefaktov.	43
4.3	<i>Precision</i> a <i>recall</i> pre klasifikáciu pohybových artefaktov po zhľúčení tried 2 a 3. .	44
4.4	<i>Precision</i> a <i>recall</i> pre klasifikáciu čitateľnosti srdečného rytmu.	45

Rada by som podľakovala vedúcemu práce doc. Ing. Pavlovi Smrčkovi, Ph.D. za odborné rady a konzultácie ohľadom tvorby práce a experimentu. Zároveň by som chcela podľakovať Ing. Radimovi Klimentovi, Ph.D. za cenné rady týkajúce sa využitia metód umelej inteligencie v oblasti biologických signálov. Špeciálne podľakovanie patrí aj všetkým účastníkom experimentu, bez ktorých by táto práca nebola možná.

Vyhľásenie

Prehlasujem, že som predloženú prácu vypracovala samostatne a že som uviedla všetky použité informačné zdroje v súlade s Metodickým pokynom o dodržiavaní etických princípov pri príprave vysokoškolských záverečných prác.

Beriem na vedomie, že sa na moju prácu vzťahujú práva a povinnosti vyplývajúce zo zákona č. 121/2000 Sb., autorského zákona, v znení neskorších predpisov, hlavne skutočnosť, že České vysoké učení technické v Praze má právo na uzavretie licenčnej zmluvy o využití tejto práce ako školského diela podľa § 60 odst. 1 citovaného zákona.

V Prahe dňa 9. mája 2024

Abstrakt

Práca sa zaobrá automatickou detekciou pohybových artefaktov z elektrokardiogramu. V rámci riadeného experimentu bola vytvorená anotovaná dátová sada obsahujúca 4602 segmentov EKG signálu dlhých dve sekundy. Záznamy boli vyhotovené počas fyzickej aktivity rôznych intenzít, segmenty sú klasifikované podľa štyroch rôznych stupňov rušenia. Na meranie bol použitý nositeľný snímač a tri rôzne druhy elektród - Ag/AgCl, chróm-niklové a textilné elektródy - pričom posledné vykazujú najväčšiu odolnosť voči pohybovým artefaktom. Navrhnuté boli dva hlboké konvolučné modely, jeden na klasifikáciu fyzických aktivít, druhý na klasifikáciu pohybových artefaktov. Presnosť klasifikácie pohybových aktivít dosahuje 85,67 %, presnosť klasifikácie pohybových artefaktov 87,62 %. Výsledný model dokáže odlišiť segmenty s čitateľným a nečitateľným srdečným rytmom s presnosťou 98,70 %.

Kľúčové slová pohybový artefakt, elektrokardiografia, klasifikácia EKG, automatická deteckcia artefaktov v EKG, spracovanie biosignálov, konvolučná neurónová sieť, hlboké učenie

Abstract

The thesis addresses the topic of automatic artefact detection in electrocardiograms. A controlled experiment was conducted, resulting in a labeled dataset comprising 4602 two seconds long ECG segments. The recordings were acquired during physical activities of varying degrees, and individual segments were categorized into four distinct classes based on the extent of the artefacts present. A wearable sensor with three different types of electrodes was used - Ag/AgCl, chrome-nickel, and textile - the latter of which revealed superior performance in mitigating motion artefacts. Two deep convolutional models were proposed: one for classifying physical activities and another for motion artefact classification. Results demonstrate an accuracy of 85.67 % for physical activity classification and 87.62 % for motion artefact classification. Furthermore, the model exhibits an accuracy of 98.70 % in correctly identifying segments with detectable and non-detectable heart rates.

Keywords motion artefact, electrocardiography, ECG classification, biosignal processing, automatic artefact detection in ECG, convolutional neural network, deep learning

Zoznam skratiek

AD	Analógovo-digitálny
Ag	Striebro
AgCl	Chlorid strieborný
ANN	Umelá neurónová sieť
BPTT	Spätné šírenie chyby v čase
CMRR	Činitel potlačenia súfázového signálu
CNN	Konvolučná neurónová sieť
EKG	Elektrokardiogram
FN	False negative
FP	False positive
ICA	Analýza nezávislých komponentov
IZS	Integrovaný záchranný systém
LSTM	Long short-term memory
RNN	Rekurentná neurónová sieť
SQA	Posudzovanie kvality signálu
SVM	Support vector machine
TN	True negative
TP	True positive

Úvod

Efektívna filtrácia pohybových a iných artefaktov v elektrokardiografickom zázname pri dlhodobom terénnom monitorovaní športovcov, alebo zásahových zložiek, zostáva nevyriešeným problémom. Keďže sa frekvenčné spektrum pohybových artefaktov do veľkej miery prekrýva s frekvenčným spektrom EKG signálu, filtrácia bez straty veľkého množstva klinicky významnej informácie nie je možná. Pri dlhodobom terénnom monitorovaní vitálnych funkcií pomocou nositeľnej elektroniky, kedy nie je nutne potrebné analyzovať celý zaznamenaný signál, je žiaduce úseky signálu, ktoré sú príliš znečistené pohybovým artefaktom, odstrániť, a sústrediť sa analýzu zvyšnej časti signálu.

Problém, ktorý v tomto prípade vzniká, je automatická detekcia nehodnotiteľných úsekov EKG signálu. Keďže ide o terénnne monitorovanie, je navyše v mnohých prípadoch potrebné, aby detekcia prebiehala v reálnom čase. Aj keď sa pohybové artefakty dajú ľahko lokali zovať pomocou vizuálnej inšpekcie, tradičné metódy spracovania signálu na časovo efektívnu automatickú detekciu nestačia. Problémom je, že aby boli schopné dosiahnuť dostatočnú úspešnosť, často sa spoliehajú na zložité metódy extrakcie príznakov, kvôli čomu nie sú použiteľné na detekciu v reálnom čase.

Cieľom práce je teda nájsť časovo efektívne riešenie na automatickú detekciu pohybových artefaktov v EKG signáli, založenú na princípoch umelej inteligencie, pričom primárne sa v tejto práci budeme venovať metódam hlbokého učenia. Pre hlboké učenie je typické, že fáza trénovania je časovo náročná, avšak samotná predikcia už nie. Hľadaniu riešenia predchádza návrh riadeného experimentu, v ktorom sa získajú dátá potrebné na trénovanie a vyhodnocovanie vybraných modelov strojového učenia. Výstupom experimentu je tiež anotovaný katalóg digitalizovaných EKG signálov, zaznamenaných počas rôznych intenzít záťaže.

..... Kapitola 1

Analýza problému

1.1 Stavba a funkcia srdca

Srdce je svalový orgán, ktorý sa nachádza v ľavej časti ľudského hrudníka, kde je chránený hrudným košom. Je zodpovedný za pumpovanie krvi do celého tela, čím rozvádzá kyslík do jednotlivých orgánov a tkanív. Z hľadiska anatómie je srdečná dutina rozdelená priečnymi hrudkami na ľavé a pravé srdce. Tie sú potom každé rozdelené na dve ďalšie časti - pravú a ľavú predsieň, a pravú a ľavú komoru. Do pravej predsieňe prúdi odkysličená krv z tela cez hornú a dolnú dutú žilu, z kade ďalej tečie cez trikuspidálnu trojcípu chlopňu do pravej komory. Tá následne krv pumpuje cez plúcne tepny do plúc na okysličenie. Naopak do ľavej predsieňe tečie cez plúcne žily okysličená krv, kde následne prúdi cez mitrálnu dvojcípu chlopňu do ľavej komory, z kade sa dostáva cez aortu do krvného obehu [1][2].

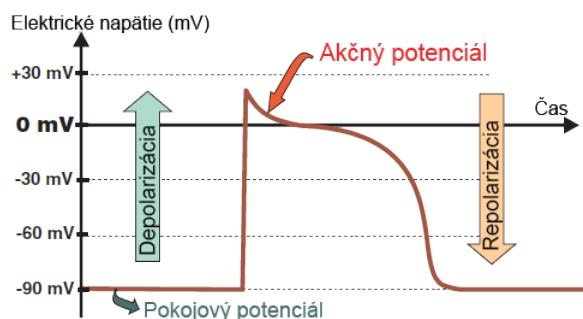
Dráždivé tkanivo, z ktorého je srdečný sval tvorený, je charakteristické **excitabilitou**, teda schopnosťou reagovať na elektrické impulzy. Svalovina srdca, alebo myokard, umožňuje rytmické kontrakcie srdca - **systolu a diastolu**. Pod systolou rozumieme časť srdečného rytmu kedy sa srdečný sval stahuje, a vytláča tak krv z komôr do tepien. Primárne zahŕňa kontrاكciu komôr, ktorá vedie k prúdeniu krvi do systémového obehu. Časť srdečného rytmu, kedy dochádza k relaxácii srdečného svalu a následnému naplneniu srdca krvou, sa nazýva diastola. Komory sa v tomto bode uvoľnia, čo umožní prúdenie novej krvi z predsieň [1].

1.1.1 Akčný potenciál srdcovej membrány

Elektrické impulzy, na ktoré bunky srdečného svalu reagujú, spontánne vznikajú v špecializovaných bunkách srdca - tie sa nazývajú kardiostimulátorové bunky. Počas srdečného cyklu bunky tvoriace srdce prechádzajú z **polarizovaného** stavu, teda pokojového, do stavu **depolarizovaného**, teda excitovaného. V polarizovanom stave dosahuje pokojový elektrický potenciál medzi povrchom a vnútrom bunky -90 mV [3]. Elektrický stimul vyvoláva akčný potenciál, ktorý sa dá rozdeliť na päť fáz.

- **Fáza 0** - depolarizácia v dôsledku prudkej zmeny polarity bunkovej membrány. Následkom je nárast akčného potenciálu až na 30 mV.
- **Fáza 1** - prvotná repolarizácia, v tomto bode začína akčný potenciál klesať.
- **Fáza 2** - nazývaná aj plató, ide o dlhší interval, v ktorom sa polarita bunkovej membrány stabilne blíži k nule. Akčný potenciál je vďaka tejto fáze výrazne dlhší a umožňuje tak trvácnú kontrakciu srdcového svalu.
- **Fáza 3** - repolarizácia v dôsledku prudkej zmeny polarity bunkovej membrány. Bunka sa vračia do polarizovaného stavu.
- **Fáza 4** - interval medzi dvoma akčnými potenciálmi, kedy bunková membrána dosahuje pokojový elektrický potenciál.

Jednotlivé fázy akčného potenciálu sú ilustrované na obrázku 1.1, kde je v čase zobrazená hodnota akčného potenciálu srdcovej membrány [4][3].



■ **Obr. 1.1** Akčný potenciál srdcovej membrány [5].

1.2 Elektrokardiografia

Proces získavania elektrokardiogramu (EKG) nazývame elektrokardiografia. Práve vyšie uvedený stručný popis anatómie a fungovania ľudského srdca je klúčový pre správnu interpretáciu vzniku EKG. „Elektrokardiografia je metóda, ktorá zaznamenáva elektrickú aktivitu srdca v čase. Zmeny v rozdiele elektrického potenciálu, teda napäti, ktoré vznikajú počas depolarizácie a repolarizácie myokardiálnych vlákien, sú zaznamenávané elektródami umiestnenými na povrchu hrudníka a končatinách. Zdrojom týchto elektrických potenciálov sú kontraktívne bunky srdcového svalu (kardiomyocyty).“¹ [6]

V tejto práci sa budeme venovať najmä záťažovej elektrokardiografii, teda **ergometrii**. Aj keď princíp zaznamenávania EKG je ten istý, toto vyšetrenie so sebou nesie určité špecifiká, hlavne ak je vykonávané v teréne. Keďže sa zaznamenáva srdečná aktivita pri fyzickej činnosti, nie je možné, aby mala na sebe sledovaná osoba štandardne umiestnené elektródy. Často musí byť použitý aj iný druh elektród, k tomu sa ale bližšie dostaneme v nasledujúcej časti práce.

¹Pôvodné znenie: „Electrocardiography is a method that registers electrical activity against time. The changes in electrical potential difference (voltage) during depolarization and repolarisation of the myocardial fibers are recorded by electrodes positioned on the surface of the chest and on the limb (limb leads). The sources of the electrical potentials are contractile cardiac muscle cells (cardiomyocytes).“

Vykreslovanie aj interpretácia EKG krivky už sice vo väčšine prípadov prebieha pomocou počítačom riadených EKG systémov, avšak tie stále vizuálne napodobňujú klasickú analýzu na milimetrovom papieri, vrátane tlačeného výstupu. Preto sú fyziologické intervaly, najmä v medicínskej literatúre, často uvádzané v milimetroch. Pre technický charakter tejto práce budeme hodnoty popisujúce dĺžku trvania uvádzať v časových jednotkách, najčastejšie milisekundách (ms). Amplitúdu krivky budeme popisovať v jednotkách elektrického napätia, v prípade EKG konkrétnie v milivoltoch (mV).

1.2.1 Elektródy a zvody

Na meranie zmien napäťia v srdečnom elektrickom poli sa používajú rôzne druhy elektród, z hľadiska funkčnosti rozlišujeme pri EKG dva druhy. **Aktívne elektródy** merajú meniaci sa elektrický potenciál na mieste, na ktorom sú umiestnené. Druhým typom sú **referenčné alebo nulové elektródy**, ktoré udržiavajú stabilný potenciál, zvyčajne nulový. Spojením dvoch elektród vzniká **zvod** - imaginárna línia pozdĺž ktorej je meraný elektrický signál. Zvody klasifikujeme na **bipolárne** a **unipolárne**. Bipolárne zvody sa skladajú z dvoch aktívnych elektród, zatiaľ čo unipolárne zvody z jednej aktívnej elektródy a jednej nulovej. Pri elektrokardiografickej vyšetrení vykonávanom v ambulancii sa EKG zaznamenáva pomocou štandardizovaného 12-zvodového systému, ktorý má predpísané rozloženie elektród.

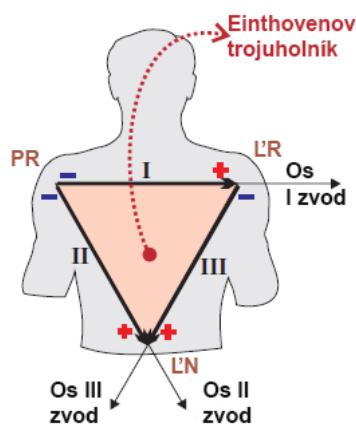
1.2.2 Einthovenove končatinové zvody

Prvé tri zvody využívané pri 12-zvodovom EKG sú Einthovenove končatinové zvody. Ide o bipolárne zvody, na získanie ktorých potrebujeme 4 elektródy - na ľavej hornej končatine (LR), pravej hornej končatine (PR), ľavej dolnej končatine (LN) a pravej dolnej končatine (PN). Elektróda na pravej dolnej končatine je nulová, ostatné sú aktívne. Tieto elektródy sa zvyčajne umiestňujú na predlaktie a predkolenie, na presnom umiestnení nezáleží, je však potrebné zabezpečiť vzdialenosť minimálne 10 centimetrov od srdca [7].

Zvody, ktoré vzniknú spojením týchto elektród, označujeme rímskymi číslicami.

- **I. štandardný zvod** - získame ho ako rozdiel potenciálov medzi elektródami na ľavom a pravom predlaktí.
- **II. štandardný zvod** - získame ho ako rozdiel potenciálov medzi elektródami na pravom predlaktí a ľavom predkolení.
- **III. štandardný zvod** - získame ho ako rozdiel potenciálov medzi elektródami na ľavom predlaktí a ľavom predkolení [3].

„Štandardné končatinové zvody snímajú srdcové potenciály vo frontálnej rovine. Spojením troch štandardných zvodov vzniká **rovnostranný Einthovenov trojuholník**, v ktorého približnom strede sa nachádza srdce - v polohe ako sa nachádza v hrudníku.“[3] Tento trojuholník sa používa aj na určenie elektrickej osi srdečnej, ktorou sa ešte budeme zaoberať neskôr v práci.

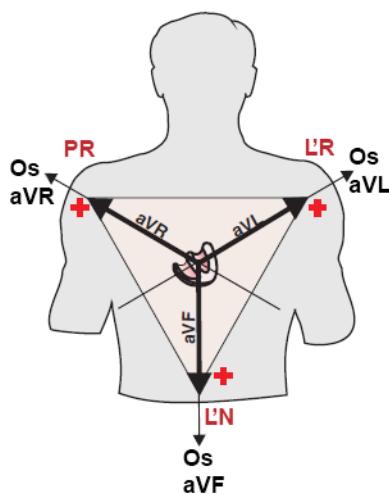


■ Obr. 1.2 Einthovenove končatinové zvody [8].

1.2.3 Goldbergove končatinové zvody

Goldbergove končatinové zvody sú opäť tri, v tomto prípade ale unipolárne - každý je kombináciou jednej aktívnej a jednej nulovej elektródy. Na ich získanie sa využívajú potenciály z tých istých elektród ako pri Einthovenových zvodoch. Nulová elektróda sa získava prepojením ostatných dvoch, čím sa potenciál aktívnej elektródy umelo zvýši. Od tejto skutočnosti je odvozený aj pojem **augmentovaný zvod** a značenie **aV** ($a = augmented = zvýšené$ a $V = voltage = napätie$). Tretie písmeno za skratkou aV značí pozíciu aktívnej elektródy.

- **aVR** - aktívna elektróda je umiestnená na pravom predlaktí, záznam je prevrátený obrazom I. štandardného zvodu.
- **aVL** - aktívna elektróda je umiestnená na ľavom predlaktí, záznam pri tomto zvode sa podobá na I. štandardný zvod.
- **aVF** - aktívna elektróda je umiestnená na ľavom predkolení, záznam pri tomto zvode sa podobá na III. štandardný zvod [3][7].

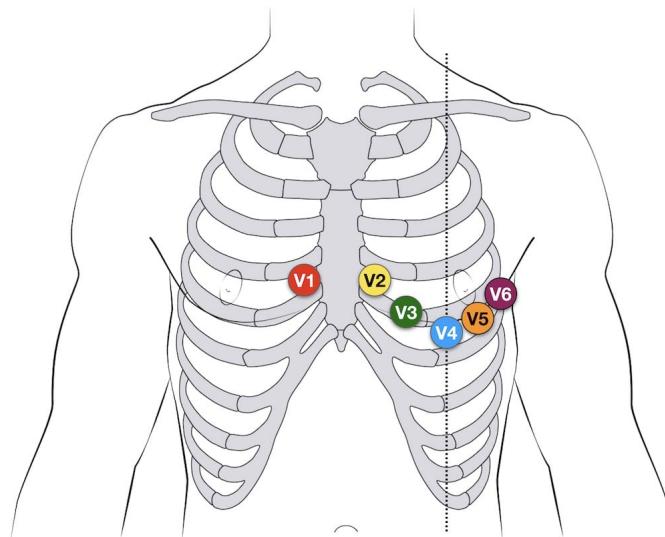


■ Obr. 1.3 Goldbergove končatinové zvody [8].

1.2.4 Wilsonove hrudné zvody

Zvyšných šest zvodov sa nachádza na hrudníku, všetky sú unipolárne a označujú sa V1 až V6. Na rozdiel od elektród využívaných Einthovenovými a Goldbergovými zvodmi majú tieto elektródy exaktne určenú pozíciu, ktorá je definovaná polohou jednotlivých rebier [3][7]. Predpísané polohy jednotlivých elektród nebudeme bližšie rozpisovať, ilustrované sú na obrázku 1.4.

Hrudné zvody snímajú elektrickú aktivitu srdca v horizontálnej rovine. „Tvar krivky EKG zaznamenaný pomocou unipolárnych hrudných zvodov determinuje vzájomný vzťah polohy snímajúcej elektródy k smeru šírenia sa vzruchu v srdci. Vzruch v srdci sa šíri smerom od sínusového uzla v pravej predsieni k srdcovému hrotu.”[3]



■ Obr. 1.4 Wilsonove hrudné zvody [9].

Dôležité je spomenúť, že pri dlhodobom terénnom monitorovaní sa často využíva 1-zvodový systém, na ktorý sú potrebné iba dve alebo tri elektródy. Tie sú často umiestnené práve na hrudníku - prvá elektróda na jednom z miest V1 až V6, druhá zrkadľovo na druhej polovici hrudníka, a tretia pod ich úrovňou, v oblasti brucha. Takýmto spôsobom sa minimalizuje počet použitých elektród a káblov potrebných na ich zapojenie, čo je pri dlhodobom monitorovaní prioritou [10].

1.3 Typy povrchových elektród

Elektródy používané v elektrokardiografii vieme rozdeliť na povrchové a hĺbkové elektródy. Povrchové elektródy sa umiestňujú na pokožku, zatiaľ čo hĺbkové elektródy sa aplikujú priamo do srdečného svalu. Pre účely tejto práce nás budú zaujímať iba povrchové elektródy, hĺbkové majú svoje miesto v medicíne najmä pri operatívnych zákrokoch.

Použitie vhodného typu povrchových elektród je rozhodujúce pre kvalitu výsledného EKG záznamu, pričom rôzne situácie si vyžadujú rôzne druhy elektród. „Keďže EKG je záznam bio elektrických potenciálov na povrchu tela, rozhranie medzi kožou pacienta a elektródami zaznamenávajúcimi EKG je kritické. Významná časť artefaktov zavedených do EKG záznamov

sa vyskytuje práve na tomto rozhraní a je spôsobená bud' neadekvátnou prípravou kože, alebo nedostatočným kontaktom medzi kožou a elektródou.”² [11] V nasledujúcej časti si predstavíme dva bežné typy povrchových elektród, so zameraním na záťažovú terénnu elektrokardiografiu.

1.3.1 Argentchloridové elektródy

Súčasne najpoužívanejším druhom elektród v medicíne sú argentchloridové elektródy, skrátené Ag/AgCl elektródy. „Ich názov pochádza od chloridu strieborného AgCl - argentchloridu, sú základom nie len referenčných elektród pre najrôznejšie analytické systémy, ale zároveň základom väčšiny elektród určených pre snímanie biologických signálov na povrchu tela.”[12] Kovová časť tejto elektródy sa skladá zo striebra, na povrchu ktorého je vrstva chloridu strieborného. Ako elektrolyt, teda materiál ktorý zabezpečí vedenie elektrického prúdu, sa pri týchto elektródach v medicíne používa fyziologický roztok [12]. V tejto kapitole sa vzhľadom na zamearanie na dlhodobé terénné monitorovanie budeme venovať iba jednorazovým lepiacim Ag/AgCl elektródam. Pre úplnosť však spomenieme, že sa v klinickej praxi vyskytujú aj plošné opakovane použiteľné, tie sa však kvôli nutnosti prípravy pokožky vodivým géjom a masívnej konštrukcii na dlhodobé monitorovanie vôbec nepoužívajú.

Jednou z výhod Ag/AgCl elektród je nízka impedancia, teda kladenie minimálneho odporu elektrickému prúdu, kvôli čomu je signál zachytený týmito elektródami dostatočne presný. Ďalšou dôležitou výhodou je pevný kontakt s kožou pacienta, ktorý zaručuje spoľahlivý prenos elektrického signálu aj pri pohybe. Tieto elektródy majú aj nevýhody, ktoré sú najvýznamnejšie práve pri terénnom a dlhodobom monitorovaní. Bežná Ag/AgCl elektróda je určená len na jedno použitie a odporučená doba skladovania je menej ako jeden rok, po odlepení, či vypršaní doby skladovania, prichádza o svoje pozitívne vlastnosti [13]. „Dlhodobé monitorovanie pomocou týchto elektród nie je vhodné, lebo bunky stratum corneum (vonkajšej vrstvy kože) sa v priebehu 24 hodín regenerujú a abrazívny efekt zmizne. Dráždenie pokožky je navyše nepríjemné a ak sú elektródy použité v kombinácii s gélmami, riziko podráždenia pokožky výrazne stúpa. V neposlednom rade ide aj o nepohodlie súvisiace s osobnou hygienou, ked'že s nalepenými elektródami sprchovanie nie je možné.”³ [13]

1.3.2 Textilné elektródy

Za posledné roky dostupnosť inteligentných nositeľných zariadení rapídne rastie, spolu s čím výrazne napriekde aj výskum v oblasti využitia textilných elektród. Tie nie sú primárne určené na ambulantné monitorovanie, ale na terénné monitorovanie pri stresových a fyzicky náročných profesiách, akými sú zásahové zložky, prípadne na voľnočasové monitorovanie pri športových aktivitách. Textilné elektródy sú väčšinou integrované do oblečenia, alebo do hrudného pásu, a štandardne sa využíva 1-zvodový EKG systém s dvoma elektródami [10]. „Potenciálnou výhodou suchých elektród integrovaných do textilu je to, že sú flexibilné (kvôli čomu sú schopné lepsiemu prispôsobeniu sa telu ako plošné pevné elektródy) a umývateľné, takže sú znova použiteľné.

²Pôvodné znenie: „As the ECG is a recording of bioelectrical potentials made at the body surface, the interface between the patient's skin and the recording electrodes of the ECG is critical. Much of the artifact introduced into ECG recordings occurs at this junction and is caused by inadequate skin preparation or in-adequate skin-electrode contact.”

³Pôvodné znenie: „This measure is not suitable for long-term monitoring because the cells of stratum corneum (outermost layer of the skin) regenerate from deeper skin layers during 24 hours, and the abrasion effect disappears; also, skin abrasion is unpleasant and, if used together with gels, significantly increases the risk of skin irritation. Finally, there is also the personal inconvenience of not being able to shower or bathe while using the electrodes.”

Táto vlastnosť znižuje množstvo spotrebného materiálu potrebného na dlhodobé monitorovanie, ktoré je nevyhnutné v prevádzkových prostrediach akými sú vojenské alebo vesmírne operácie.”⁴ [14]

V literatúre sa najčastejšie opisujú tri rôzne metódy výroby textilných elektród, všetky zdieľajú myšlienku využitia vodivých vlákien, alebo povlakov, na dosiahnutie prenosu elektrického signálu. Vodivé vlákna a povlaky obsahujú kovové častice ako napríklad striebro, uhlík, alebo grafén, v prípade prefabrikovaných tkanín ide o štandardné materiály ako nylon alebo polyester, potiahnuté tenkou vrstvou striebra, prípadne iného kovu [15]. Prvou metódou je využitie prefabrikovaných textilných tkanív, ktoré sú prísité na odev z vnútornej strany [16]. Výhodou tejto metódy je, že spomedzi spomínaných metód je najmenej prácna, ale zároveň neposkytuje takú flexibilitu pri návrhu dizajnu ako nasledujúce dve metódy. Ďalšou metódou je využitie vodivých vlákien, ktorími sa následne na odev za pomocí tkania alebo pletenia vyšíva požadovaný vzor [13][17]. Výhodou je možnosť vytvorenia hustejšej vrstvy vodivého materiálu [14]. Poslednou možnosťou je využitie vodivých farieb alebo povlakov, ktoré sú pomocou sietotlače, alebo inej techniky, tlačené na odev. Tento postup dosahuje dobré výsledky, ale je výrazne drahší a komplikovanejší na výrobu ako predošlé dva [18][19].

Zvýšenie komfortu monitorovania pri zachovaní dostatočnej spoľahlivosti a presnosti snímania EKG je hlavným cieľom výskumu v oblasti textilných elektród. Tie sú schopné eliminovať mnohé nevýhody spojené s tradičnými Ag/AgCl elektródami, ako dráždenie pokožky, či vysychanie elektród [14]. Nevýhodou oproti lepiacim argentchloridovým elektródam, a zároveň aj najväčšou výzvou, je zabezpečenie dostatočného kontaktu medzi kožou a elektródou, čo môže predstavovať problém pri pohybe a s ním spojeným potením. „Meniaca sa vzdialenosť a trenie, ktoré sú spôsobené pohybom tela voči povrchu elektródy, sú hlavným zdrojom chýb - takzvaných pohybových artefaktov.”⁵ [20]

1.4 EKG krivka

V nasledujúcej časti práce popíšeme jednotlivé časti EKG krivky, ktoré sú charakteristické pre jej fyziologický priebeh. **Izoelektrická línia**, alebo čiara, je základom pre každé meranie. Reprezentuje časť signálu, kedy je stav srdca polarizovaný. V EKG zázname ide o rovnú horizontálnu líniu, ktorá slúži ako referenčná hladina k interpretácii jednotlivých vln.

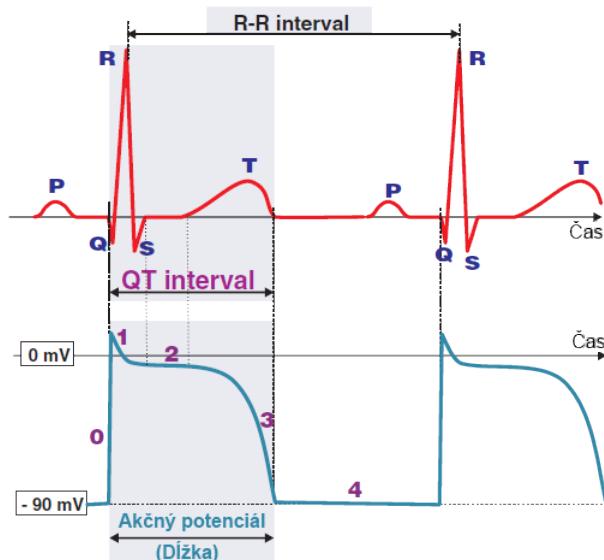
1.4.1 Genéza signálu

Pri depolarizácii a repolarizácii svalových vlákien dochádza k zmene napäťia. To sa na EKG krivke prejavuje ako vlny s rôznou polaritou, ktorá závisí od smeru elektrickej aktivity relatívne k zvodu. „Vlny, ktoré sa nachádzajú nad úrovňou izoelektrickej čiary, označujeme ako **pozitívne**, tie, ktoré sú pod jej úrovňou ako **negatívne**. Vlny, ktorých jedna časť je pozitívna, druhá negatívna, sú **dvojfázové**.”[3] V EKG krivke pozorujeme P-vlnu, Q-vlnu, R-vlnu, S-vlnu a T-vlnu, ktoré sa typicky nachádzajú v zázname práve v tomto poradí. U zhruha jednej štvrtiny populácie je viditeľná aj šiesta U-vlna, kvôli jej nízkej amplitúde to však nie je pravidlom [6].

⁴Pôvodné znenie: „The potential advantage of dry electrodes that are textile integrated is that they are both flexible (making them more conformal to the body than traditional rigid disk electrodes) and washable, so it is feasible to use and reuse them. This reduces the consumables required to conduct long-term health monitoring, which is essential for applications in operational environments such as military and space operations.”

⁵Pôvodné znenie: „Varying distance and friction between the electrode, caused by the movements of the body and surface of an object, are forming a major source of error—so-called motion artifact.”

Na obrázku 1.5 je možné vidieť vzťah medzi akčným potenciálom srdcovej membrány a genézou EKG krivky.



■ Obr. 1.5 Súvis akčného potenciálu srdcovej membrány a EKG krivky [5].

- **P-vlna** vzniká pri depolarizácii predsiení. Keďže svalová hmota predsiení je relatívne malá, na EKG krivke pri príslušných zvadoch pozorujeme malú oblú pozitívnu vlnu.
- **QRS komplex**, nazývaný aj komorový komplex, reprezentuje depolarizáciu komôr, obsahuje tri ostré za sebou idúce vlny. Z dôvodu väčzej svalovej hmoty je amplitúda vln komplexu výrazne vyššia.
- **T-vlna** vzniká pri repolarizácii komôr, podobne ako pri P-vlne ide o malú oblú pozitívnu vlnu [21][3].

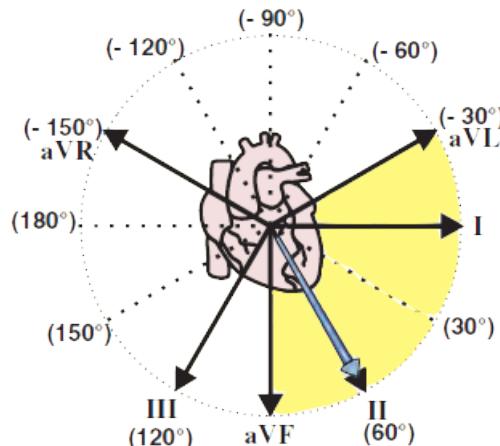
1.4.2 Elektrická os srdečná

Aktivita srdca sa dá popísať mnohými vektormi, ktoré reprezentujú smer a silu elektrickej aktivity vznikajúcej v srdeči. Samostatne vieme určiť napríklad aj elektrickú os srdcových komôr, pomocou vektorovej aritmetiky. „Konečný vektor, po všetkých sčítaniach, odčítaníach a zmenách smeru, reprezentuje elektrickú os srdcovej komory. Rovnako má každá vlna a každý segment tiež svoj príslušný vektor, vektor P-vlny, vektor S-T segmentu, alebo QRS vektor. EKG zachytáva tieto vektory počas toho, ako prechádzajú pod elektródou.“⁶ [7]

Amplitúda vlny zobrazenej na EKG krivke závisí od uhlu, ktorý zviera vektor elektrického impulzu so zvodom. Ak je vektor paralelný s osou zvodu, amplitúda bude pri danom zvode maximálna, a klesá spolu s narastajúcim uhlom medzi nimi. V prípade, že sú na seba kolmé, na EKG krivke je viditeľná izoelektrická línia. Od orientácie vektoru elektrického impulzu zase záleží, či bude vlna na EKG krivke zobrazená ako pozitívna, alebo negatívna.

⁶Pôvodné znenie: „That final vector, after all of the addition, subtraction, and direction changes, is known as the electrical axis of the ventricle. In the same way, each wave and segment has its own respective vector. There is a P-wave vector, a T-wave vector, an ST segment vector, and a QRS vector. The ECG is a measurement of these vectors as they pass under an electrode.”

- **Pozitívna vlna** vzniká, ak sa pozitívny impulz hýbe smerom k elektróde. Ked'že výsledkom depolarizácie je pozitívny potenciál, ak sa depolarizácia hýbe smerom k elektróde, vzniká pozitívna vlna. Opak platí pre repolarizáciu, pri ktorej vzniká negatívny potenciál - vlna bude pozitívna, ak sa hýbe smerom od elektródy.
- **Negatívna vlna** vzniká, ak sa pozitívny impulz hýbe smerom od elektródy. Z tvrdenia vyššie vyplýva, že ak sa depolarizácia hýbe v smere od elektródy, zaznamenaná vlna bude negatívna, a analogicky platí to isté, keď sa repolarizácia hýbe smerom od elektródy [7][22].



■ **Obr. 1.6** Elektrická os srdečná [23].

Fyziologicky je elektrická os srdečná orientovaná medzi -30° až $+90^\circ$, teda v ľavom dolnom kvadrante, ako je možné vidieť na obrázku 1.6. Ked'že sa elektrický impulz v srdci šíri od pravej predsiene smerom k srdcovému hrotu, fyziologicky os približne zodpovedá orientácii srdca v hrudnej dutine [3]. V prípade patológie označujeme elektrickú os ako derivovanú doprava, alebo derivovanú doľava.

1.4.3 Interpretácia EKG

Elektrokardiogram je kvôli dostupnosti a neinvazívному charakteru tejto metódy najčastejšie využívaná metóda v kardiológii. Dôkladnou analýzou záznamu je možné diagnostikovať rôzne srdcovo-cievne ochorenia, ako napríklad arytmie, či infarkt myokardu. Najdlhšou súvisle interpretovanou časťou v EKG krivke je QRS komplex, ktorý je tvorený zhľukom troch rovnomenných vln. Okrem samotných vín v rámci EKG krivky interpretujeme aj trvanie dvoch základných charakteristík - segmentov a intervalov.

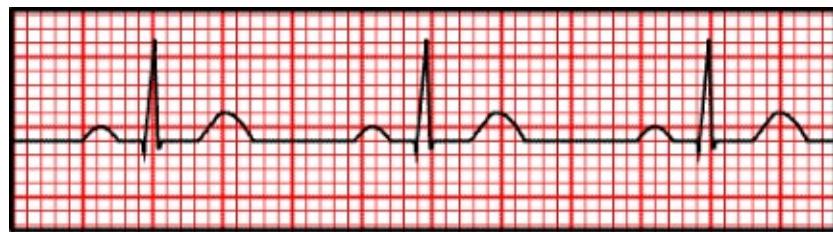
- **Segment** je časť izoelektrickej línie medzi jednotlivými vlnami, interpretujeme napríklad S-T alebo P-R segment.
- **Interval** je ohraničený začiatkom jednej a začiatkom druhej vlny. Tieto vlny môžu byť buď z toho istého srdečného cyklu, ako napríklad P-R alebo Q-T interval, alebo z dvoch po sebe idúcich cyklov, ako v prípade R-R intervalu [6].

Pri interpretácii EKG sa kladie dôraz na dobu trvania a amplitúdy jednotlivých vln, segmentov, aj intervalov, pričom namerané hodnoty sa porovnávajú s fyziologickými. V tejto práci sa diagnostike srdcovo-cievnych ochorení venovať nebudeme, avšak v odbornej literatúre je možné nájsť veľké množstvo relevantných informácií k tejto téme [6][3][21].

1.5 Artefakty v EKG

Artefakty sú definované ako nežiaduce signály, alebo interferencie, ktoré nesúvisia s elektrickou aktivitou srdca a môžu viest k nesprávnej interpretácii skutočného EKG signálu. Pochádzajú z rôznych zdrojov fyziologického, technického, alebo environmentálneho pôvodu. Keď sú artefakty superponované na EKG signáli, izoelektrická línia alebo jednotlivé vlny pôsobia skreslené, čo môže viest k nesprávnej diagnostike. Niektoré artefakty môžu svojim vzhľadom napodobňovať klinicky významné arytmie, ako napríklad fibriláciu predsienní alebo komorovú tachykardiu. Veľkú časť týchto artefaktov nie je možné odstrániť bez straty dôležitej informácie.

Jedným z možných zdrojov artefaktov je chybné zapojenie elektród. Artefaktom tohto pôvodu sa ďalej nebudeme venovať, iba pre úplnosť spomenieme, že môžu spôsobiť prevrátený alebo inverzný signál pri postihnutých zvodoch [24][25]. V nasledujúcej časti práce si popíšeme artefakty, so zameraním na tie spôsobené fyzickou činnosťou. Príklad EKG krivky, na ktorej je zaznamenaný fyziologický **sínusový rytmus**, bez znečistenia artefaktmi, je možné vidieť na obrázku 1.7.



■ Obr. 1.7 Sínusový rytmus [26].

1.5.1 Kolísanie izoelektrickej línie



■ Obr. 1.8 Kolísanie izoelektrickej línie [26].

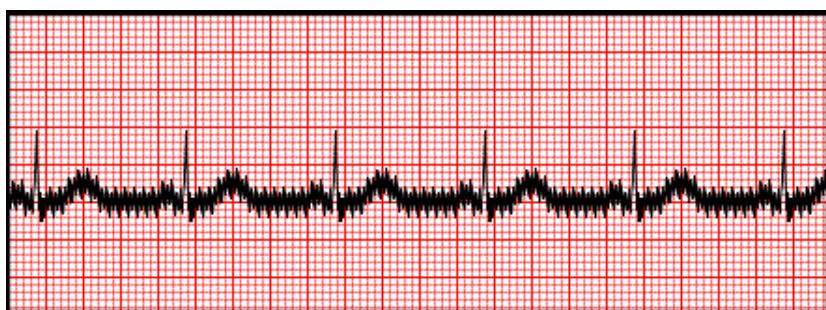
Ide o nízkofrekvenčný artefakt prejavujúci sa v EKG signáli ako postupný posun izoelektrickej línie v čase. Kolísanie izolínie môže pochádzať z rôznych zdrojov, často ide o respiračný

artefakt spôsobený pohybom hrudníka pri dýchaní. Nedostatočný kontakt elektródy s kožou, prípadne nesúlad impedancií, môže spôsobiť kolísanie keď elektrický signál narazí na odpor na rozhraní koža-elektróda. Častým zdrojom je aj mimovoľný pohyb elektród spôsobený nedostatočnou fixáciou ku koži [27].

Špecifickým druhom kolísania izoelektrickej línie je takzvaný **abrupt**, ktorý je charakteristický rýchlym preskokom. Tento druh kolísania úzko súvisí s pohybovými artefaktmi, keďže je často spôsobený dotykom elektródy, a je ťažké ho odstrániť bez straty informácie.

Medzi najpoužívanejšie metódy odstránenia kolísajúcej izolíne patria analógové alebo digitálne filtre s konečnou alebo nekonečnou odozvou, ktoré sú schopné selektívne prepúšťať alebo tlmit špecifické frekvenčné zložky signálu. Analógové filtre sú zabudované priamo v zariadení snímajúcim EKG, kde filtrovajú signál ešte pred digitalizáciou. Keďže ide o nízkofrekvenčný artefakt, využívajú sa filtre typu horná prieplust, ktoré prepúšťajú frekvencie vyššie ako stanovená hranica a tlmia nižšie. Porovnanie efektívnosti týchto filtrov je možné nájsť v odbornej literatúre, pričom sa kladie dôraz na čo najmenšiu stratu informácie v pôvodnom EKG signáli [27][28].

1.5.2 Sieťové rušenie



■ Obr. 1.9 Sieťové rušenie [26].

Zdrojom sieťového rušenia je striedavý prúd. Ide o rušenie s frekvenciou 50 Hz⁷, ktoré sa prejavuje ako periodické fluktuácie v podobe špičiek superponovaných na skutočnej EKG krvke. Tento artefakt môže vznikať ako dôsledok elektromagnetickej väzby medzi elektrickými zvodmi, prípadne v dôsledku nedostatočného uzemnenia [29]. „Prítomnosť iných elektrických zariadení v miestnosti, kde sa zaznamenáva EKG, môže spôsobiť záznamy s viditeľným elektrickým rušením. V týchto prípadoch by mali byť všetky zariadenia, ktoré môžu rušiť EKG signál, vypnuté. Medzi takéto zariadenia patria mobilné telefóny vo vzdialosti menšej ako 25 cm od zariadenia zaznamenávajúceho EKG, elektrické lôžka, či chirurgické alebo fluorescenčné lampy.”⁸ [24]

Zabezpečenie správneho uzemnenia EKG zariadenia a tienenia káblov pred elektromagnetickým rušením znižuje pravdepodobnosť výskytu artefaktov. Navyše majú systémy na monitorovanie EKG v sebe často integrované analógové filtre, ktoré tento artefakt potláčajú. Keďže

⁷Na území Európy sa štandardne elektrické zariadenia napájajú na striedavý prúd s frekvenciou 50 Hz, v iných častiach sveta je to často 60 Hz.

⁸Pôvodné znenie: „The presence of other electrical devices in the room where the ECG is being conducted may cause recordings with electrical interference. In such cases, any device that may interfere with the ECG signal should be turned off: these include cell phones within 25 cm of the ECG sensor module, electrical beds, surgical and fluorescent lamps.”

ide o opakované rušenie so známou frekvenciou, najčastejšie sa využívajú na jeho filtráciu hrebeňové filtre⁹, ktoré sú schopné potláčať konkrétnu frekvenciu, prípadne iné varianty pásmovej zádrže, ako napríklad Butterworthov filter [30].

1.5.3 Pohybové artefakty



■ Obr. 1.10 Pohybový artefakt [26].

Pohybové artefakty sú najväčším problémom pri záťažovom testovaní. Zdrojom týchto artefaktov sú samotné nárazy spôsobené pohybom, zmena kontaktu medzi kožou a elektródou, či zmena impedancie na rozhraní koža-elektróda [31]. Špecifickým typom pohybového artefaktu sú **myopotenciály**, ktoré vznikajú kvôli svalovým kontrakciám.

Odstránenie pohybových artefaktov je najväčšou výzvou spomedzi spomínaných EKG artefaktov. Dôvodom je, že frekvenčné spektrum týchto artefaktov sa do významnej miery prekrýva so spektrom EKG, takže odstránenie bez straty dôležitej informácie nie je možné [32]. Aj keď toto tvrdenie platí do istej miery pre väčšinu vyššie uvedených artefaktov, pri nízkofrekvenčnom kolísaní izoelektrickej línie je vplyv filtrácie minimálny, to isté platí aj pri sieťovom rušení, keďže je úzkopásmové a dá sa tak číslicovo filtrovať. Významný problém nastáva pri filtrácii abruptov, tie však môžeme z hľadiska pôvodu radíť medzi pohybové artefakty. „Pohybové artefakty môžu produkovať signály s veľkou amplitúdou, ktoré pripomínajú P-vlny, T-vlny, či QRS-komplex. Sú prítomné počas ambulantného monitorovania a záťažových testov. Z klinického hľadiska môžu viesť k stanoveniu nesprávnej diagnózy, alebo oneskoreným či nevhodným rozhodnutiam týkajúcich sa liečby. Efektívne potlačenie pohybového artefaktu je v klinickom prostredí zatiaľ nevyriešeným problémom.”¹⁰ [33]

Existujú postupy, ktorými sa dajú pohybové artefakty potlačiť, napríklad adaptívou filtráciou, kedy sa parametre filtru dynamicky menia [31][33], tieto riešenia však často nie sú dosťatočné. V tejto práci sa nebudeme zaoberať filtráciou pohybových artefaktov, ale ich automatickou detekciou. Pri dlhodobom terénnom monitorovaní je ziadúce tieto úseky identifikovať a následne od nich signál očistiť - segmenty znečistené pohybovými artefaktami zahodiť.

⁹Často v literatúre uvádzané aj v pôvodnom anglickom znení ako *notch filter*.

¹⁰Pôvodné znenie: „Motion artifact can produce large amplitude signals in the ECG and can resemble the P, QRS, and T waveforms of the ECG. Motion artifact is prevalent during ambulatory monitoring and treadmill stress testing. From the clinical standpoint, motion artifact can result in misdiagnosis and may lead to delayed or inappropriate treatment decisions. Effective reduction of motion artifact is an unsolved problem in the clinical setting.”

1.6 Automatická detekcia artefaktov v EKG

Problém detektie pohybových artefaktov je vo svojej podstate problémom detektie anomálií. V našom prípade anomálie nebudú predstavovať poruchy srdcového rytmu, ani iné z diagnostického hľadiska patologické javy čitateľné z EKG krvky, ale samotné artefakty. Na rozdiel od detektie anomálií sa detektia pohybových artefaktov nezaoberá iba identifikáciou nesprávnych vzorov či deviácií od stanovenej normy, ale zaoberá sa aj posudzovaním kvality signálu.¹¹ Práve kvalita signálu je rozhodujúca pri ďalšom spracovaní a interpretácii EKG záznamu.

Všetky z uvedených artefaktov sú ľahko identifikovateľné pomocou vizuálnej inšpekcie, zaujímavým aspektom tohto problému je však *automatická* detektia, s ktorou majú tradičné metódy spracovania signálu problém. Práve to, že tradičné metódy na automatickú detekciu pohybových artefaktov nestačia, je motiváciou skúmať v tejto práci metódy založené na umelej inteligencii.

1.6.1 Tradičné metódy spracovania signálu

Medzi tradičné metódy spracovania signálu budeme radíť metódy zaobrajúce sa štatistickou analýzou a rôzne techniky dekompozície signálu. Patrila by sem aj analógová a digitálna filtrácia, ale kvôli prekrývajúcemu sa frekvenčnému spektru tento prístup nie je v prípade pohybových artefaktov účinný. V krátkosti uvedieme dve metódy tradičného spracovania signálov vyskytujúce sa v literatúre v kontexte posudzovania kvality signálu a detektie artefaktov.

- **Analýza nezávislých komponentov (ICA)** je metóda dekompozície signálu, ktorá dokáže rozložiť signál na množinu štatisticky nezávislých komponentov, predpokladom je, že dátá pochádzajú z iného ako Gaussovského rozdelenia. Tým, že pohybové artefakty a EKG signál pochádzajú zo štatisticky nezávislých zdrojov, táto metóda je schopná ich odseparovať [34].
- **Vlnková transformácia** funguje na podobnom princípe ako Fourierova transformácia, ale je vhodnejšia na detekciu pohybových artefaktov. Nerozkladá signál iba na harmonické zložky, ktoré pretrvávajú po celú dobu signálu, ale dokáže nájsť zložky definované špecifickou frekvenčiou a časom. Analýzou získaných vlnkových koeficientov sa dajú odhaliať časovo-frekvenčné charakteristiky pohybového signálu [35].

Nevýhodou použitia tradičných metód je, že sa často spoliehajú na analýzu špecifických charakteristik vstupných dát. Kvôli tomu nie sú schopné dobre generalizovať naprieč rôznymi množinami dát, ktoré napríklad nemusia byť zaznamenané za tých istých podmienok. Toto predstavuje problém, keďže pohybové artefakty sú veľmi variabilné, závisia od vykonávanej aktivity, ale aj od polohy a typu elektród. Ďalšou významnou nevýhodou je časová náročnosť výpočtu. Metódy umelej inteligencie sú typicky vo fáze učenia tiež časovo náročné, avšak pri predikcii už nie. Výhodou tradičných metód je dobrá interpretovateľnosť výsledkov, tá sa však dá lepšie aplikovať na analýzu vlastností pohybových artefaktov, než na samotnú automatickú detekciu.

¹¹Tento problém je v anglickej literatúre možné nájsť pod pojmom *signal quality assessment* (SQA).

1.6.2 Umelé neurónové siete (ANN)

Aby sme mohli ďalej rozoberať konkrétné architektúry neurónových sietí, ktoré sa využívajú na analýzu signálov, alebo časových rád, potrebujeme uviesť krátky opis umelých neurónových sietí ako takých. Sú to výpočtové modely, ktoré svojou štruktúrou pripomínajú ľudský nervový systém, čím sa snažia nadobudnúť schopnosť **generalizovať** a riešiť komplexné problémy.

Model neurónu obsahuje n vstupov, ktoré značíme x_1 až x_n , k ním prislúchajú váhy w_1 až w_n . Výstup neurónu y je definovaný vzorcom 1.1, dostávame ho ako lineárnu kombináciu vektoru vstupov \bar{x} a vektoru váh \bar{w} . T predstavuje prah, pri ktorom je neurón aktivovaný a f definuje **aktivačnú funkciu**.

$$y = f\left(\sum_{i=0}^n w_i x_i - T\right) \quad (1.1)$$

Tá zavádzá do modelu žiadanú nelinearitu, a mala by byť spojité a diferencovateľná kvôli učeniu pomocou gradientných optimalizačných algoritmov. Častou voľbou vo výstupnej vrstve pri binárnej klasifikácii je **sigmoida** 1.2, pri klasifikácii do viacerých tried funkcia **softmax** 1.3. Softmax narozenie od sigmoidy dáva na výstup rozdelenie pravdepodobnosti naprieč K triedami, pričom zaručuje, že súčet jednotlivých pravdepodobností bude rovný jednej [36][37][38].

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (1.2) \qquad \text{softmax}(x_i) = \frac{e^{x_i}}{\sum_{j=1}^K e^{x_j}} \quad (1.3)$$

Z hľadiska prepojenia neurónov poznáme dva rôzne druhy neurónových sietí - **dopredné a spätnoväzebné**. V dopredných sietiach sa informácia šíri iba jedným smerom, zatiaľ čo v spätnoväzebných sú umožnené aj spätné prepojenia, príkladom sú rekurentné neurónové siete. Jednotlivé neuróny sú usporiadané do lineárnych polí, tie sa nazývajú **vrstvy**. Poznáme tri rôzne typy vrstiev z hľadiska usporiadania a to vstupné, skryté a výstupné.

Optimalizáciu vektorov váh \bar{w} nazývame **učenie** neurónovej siete. V skutočnosti ide o iteratívne hľadanie minima **stratovej funkcie**. Na začiatku sú vektory váh inicializované náhodne, prípadne je možné použiť heuristiku. V každej iterácii trénovalia, teda **epocha**, sa naj-skôr vykoná **dopredný krok**, kedy sa vstupné dátá propagujú sietou až na výstup. Následne sa vypočítá strata modelu, porovnaním predikcií so správnymi hodnotami. Ako stratová funkcia pri klasifikačných úlohách sa často volí **kategerrická krízová entropia**, ktorá je zadefinovaná ako 1.4, kde c značí počet tried.

$$L = - \sum_{i=1}^c y_i \log(\hat{y}_i) \quad (1.4)$$

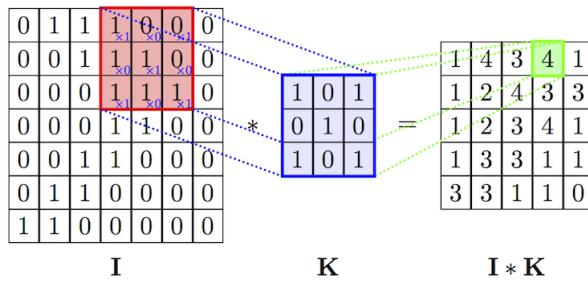
Vypočítaná strata modelu sa následne pomocou algoritmu **spätného šírenia chyby** propaguje neurónovou sietou späť. Ako posledný krok jednej epochy sa vykoná aktualizácia váh modelu, kedy sa pomocou gradientnej optimalizácie posunú ich hodnoty proti smeru gradientu, teda smerom k minimu funkcie [36][37][38]. Aktualizácia n -tej váhy je definovaná vzťahom 1.5, pričom α predstavuje hyperparameter **learning rate**, ktorý reguluje rýchlosť učenia.

$$w_n = w_n - \alpha \left(\frac{\delta L}{\delta w_n} \right) \quad (1.5)$$

Darji a spol.[39] riešili v svojej publikácii problém podobný nášmu použitím umelých neurónových sietí. Pomocou algoritmu na synchronizáciu R-špičiek a adaptívnej filtrácie odhadli z dát zložku reprezentujúcu pohybový artefakt pri štyroch rôznych fyzických aktivitách. Následne zo získaných zložiek ešte extrahovali časové a frekvenčné príznaky, ktoré potom vložili na vstup umelej neurónovej siete s desiatimi skrytými vrstvami. Na výstupe predikovali typ pohybovej aktivity s presnosťou 89,07 %. Využitie tohto postupu v reálnom čase však nie je kvôli časovo náročnému predspracovaniu dát možné.

1.6.3 Konvolučné neurónové siete (CNN)

Konvolučné neurónové siete sú určené na spracovanie viac-dimenzióvných dát, akými sú napríklad časové rady alebo obrazové dátá. Špeciálne vrstvy vykonávajú operáciu nazývanú konvolúcia, použitý filter sa nazýva **kernel**. Okno filtra sa postupne posúva cez dátá, pričom počíta jednotlivé skalárne súčiny, ktoré sa zapisujú na príslušnú pozíciu výstupnej matice. Operácia konvolúcie je znázornená na obrázku 1.11, kde je matica I konvolvovaná s kernelom K . Okrem toho, že tieto vrstvy umožňujú hierarchickú extrakciu príznakov, slúžia aj na zníženie komplexnosti modelu, keďže nie sú plne prepojené.



■ **Obr. 1.11** Konvolúcia matice s kernelom [40].

Architektúra týchto sietí zahŕňa kombináciu plne prepojených, konvolučných a poolingových vrstiev.

- **Konvolučné vrstvy** sú filtre, ktoré umožňujú neurónovej sieti extraľovať konkrétnie informácie. Výsledkom aplikácie konvolúcie na dátá sú matice nazývané **aktivačné mapy**. Tako získané mapy je možné vizualizovať a analyzovať tak získané príznaky.
- **Poolingové vrstvy** redukujú rozmer vzniknutých máp, susedné prvky sú zlúčené do jedného, pomocou matematických operácií ako sčítanie, alebo priemerovanie. Tieto vrstvy opäť redukujú komplexnosť siete a znižujú aj riziko preučenia.
- **Plne prepojené vrstvy** sú zodpovedné za integráciu informácií získaných v jednotlivých konvolučných vrstvách a následný výpočet predikcií [41][42][43].

Zhang a spol. [44] na klasifikáciu kvality EKG signálu využili kaskádu konvolučných neurónových sietí. Architektúra siete sa skladá z dvoch hlavných pod-sietí. Prvá klasifikuje signál do troch kategórií - pohybový artefakt, myopotenciál a signál s minimálnym rušením. Výstup z tejto pod-siete následne ide na vstup do druhej, ktorá ďalej klasifikuje pohybové artefakty a myopotenciály na mierne a závažné. Prvá pod-siet' sa skladá z troch samostatných sietí. Do jednej siete ide na vstup EKG signál očistený od šumu, do druhej vstupuje spekrogram signálu získaný pomocou krátkodobej Fourierovej transformácie.

Výstupy z oboch sietí idú na vstup do jedno-vrstvovej neurónovej siete obsahujúcej plne prepojenú vrstvu so softmax aktivačnou funkciou, ktorá výsledok klasifikuje do jednej z troch tried.

Dáta boli získané z II. zvodu 12-zvodového Holter monitoru, pričom dátová sada pozoštáva z 90 000 segmentov. Dĺžka jedného segmentu bola zvolená ako 4 sekundy, a segment bol anotovaný podľa dominantného artefaktu. Artefakt bol segmentu priradený v prípade, že presahoval dĺžku 2 sekundy, závažnosť artefaktu bola odvodená od amplitúdy, relatívne k amplitúde R-špičky. Vyhodnotenie zohľadňuje aj presnosť klasifikácie pri rôznych arytmiah zastúpených v dátovej sade, súhrnná presnosť bola 92,7 %. Kvôli komplexite získania dát a ich množstvu je rozsah tejto štúdie neporovnatelný s našou [44].

1.6.4 Rekurentné neurónové siete (RNN)

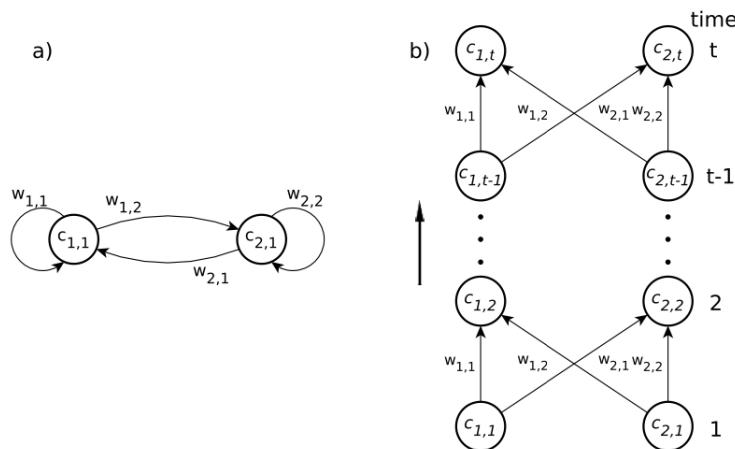
Spätné väzby v RNN umožňujú pamätať si informáciu a modelovať dátá obsahujúce časové závislosti. Pri analýze časových radov to znamená, že sú schopné efektívne riešiť problémy ako rozpoznávanie vzorov v dátach, či detekciu anomálií.

Tradičné architektúry rekurentných neurónových sietí sa spoliehajú na spätné prepojenia, príkladom je plne-prepojená RNN, kde je každý neurón v skrytej vrstve napojený na všetky ostatné neuróny. Spolu s narastajúcou vzdialenosťou strácajú schopnosť pamätať si informáciu, takže nie sú vhodné na modelovanie dlhodobých časových závislostí [45]. Druhým problémom je miznúci gradient, kedy gradient propagovaný cez mnoho časových krokov začne exponenciálne klesať, následkom čoho sa váhy aktualizujú po veľmi malých krodoch, čo vedie k stagnácii trénovania [46].

Riešením oboch problémov je novšia architektúra rekurentných neurónových sietí Long Short-Term Memory (**LSTM**). Táto architektúra využíva pamäťové LSTM bunky, ktoré majú v pamäti uložený vektor reprezentujúci ich stav. Tok informácií dnu a von z tejto bunky je kontrolovaný pomocou brán, ktoré umožňujú zachytávať aj dlhodobé vzťahy v dátach [47].

Kvôli nutnosti propagácie chyby cez rekurentné prepojenia použitie štandardného trénovacieho algoritmu spätného šírenia chyby nie je možné. Miesto toho sa najčastejšie využíva jeho rozšírená verzia, nazývaná **algoritmus spätného šírenia chyby v čase (BPTT)**. „Na konci trénovacej sekvencie sa sieť rozvinie v čase a vypočíta sa chyba pre dvojice vstupov a výstupov pomocou zvolenej metriky. Následne sa táto chyba propaguje späť sieťou a vypočíta sa aktualizácia váh pre každý krok v čase. Na záver sa váhy v rekurentnej verzii siete aktualizujú ako súčet vypočítaných zmien naprieč všetkými krokmi.“¹² [47] Ukážka rozvinutia rekurentnej neurónovej siete v čase t je na obrázku 1.12.

¹²Pôvodné znenie: „At the end of a training sequence, the network is unfolded in time. The error is calculated for the output units with existing target values using some chosen error measure. Then, the error is injected backwards into the network and the weight updates for all time steps calculated. The weights in the recurrent version of the network are updated with the sum of its deltas over all time steps.”



■ Obr. 1.12 Rozvinutie rekurentnej neurónovej siete v čase [47].

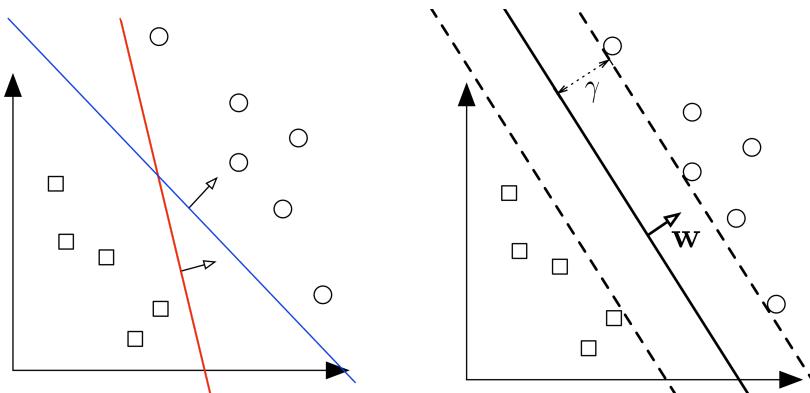
Boljanić a spol. [48] sa v ich publikácii zaoberajú detekciou EKG artefaktov pomocou LSTM neurónových sietí. Dáta, na ktorých bola táto sieť trénovaná, úzko súvisia so zámerom našej práce - EKG signály z 1-zvodového systému boli zaznamenané od horských záchranárov počas zásahu. Signál bol rozdelený na 10 sekundové segmenty, a segment bol označený ako obsahujúci pohybový artefakt ak viac ako polovica segmentu obsahovala šum, kvôli ktorému sa nedal jasne detegovať QRS-komplex. Architektúra použitej siete sa skladá z obojsmernej LSTM vrstvy (BiLSTM), ktorej výstup ide na vstup plne prepojenej vrstvy so softmax aktivačnou funkciou. Po vyladení hyperparametrov bola táto architektúra schopná dosiahnuť presnosť 90,1 % na testovacích dátach. Hlavným obmedzením tohto prístupu je dlhé časové okno.

1.6.5 Support vector machines (SVM)

SVM je trieda modelov, ktorá sa najčastejšie používa na klasifikáciu dát. Problém, ktorý tieto modely riešia, je nájdenie **optimálnej separačnej nadroviny**, ktorá maximalizuje vzdialenosť jednotlivých dátových bodov od nej. V prípade lineárne separovateľných dát je typicky možné nájsť nekonečne mnoho nadrovín separujúcich dát. SVM operujú s myšlienkom, že čím ďalej dátové body od tejto nadroviny ležia, tým istejšia je klasifikácia, a teda schopnosť modelu generalizovať narastá. Okolo nadroviny sa nachádza pásmo, v ktorom neležia žiadne body, hľadáme teda maximálny okraj¹³. Na definovanie nadroviny nám stačia body ležiace na tomto okraji, ktorých je typicky málo, takže sa pri výpočte pracuje s riedkou maticou, kvôli čomu je táto metóda výpočtovo efektívna. Body, na ktorých závisí poloha nadroviny, nazývame **podporné vektoru**¹⁴. Na obrázku 1.13 hrubá čiara reprezentuje optimálnu separačnú nadrovinu, a γ definiuje maximálny okraj [49][50].

¹³V anglickom jazyku *maximal margin.*

¹⁴V anglickom jazyku *support vectors*.



■ Obr. 1.13 Optimálna separačná nadrovina [51].

V prípade, kedy dátu nie sú lineárne separovateľné, využívajú **jadrový trik**, ktorý pomocou **jadrovej funkcie** dátu transformuje do priestoru vyšej dimenzie, v ktorej už lineárne separovateľné sú. SVM modely taktiež nevyžadujú úplnú lineárnu separabilitu, v prípade, že sa dosiahnuť nedá, sa používa mäkký okraj¹⁵, ktorý umožňuje aj nesprávnu klasifikáciu. Tá je penalizovaná, čím prispieva k zmene predpisu nadroviny. Keďže transformácia dát do vyšších dimenzíí vie byť výpočtovo náročná, jadrový trik využíva na transformáciu skalárne súčiny príznakov. Jadrové funkcie používajú rôzne jadrá, dve často využívané sú **polynomiálne jadro** 1.6, kde pre $d=1$ dostávame **lineárne jadro**, a **Gaussovské (RBF) jadro** 1.7, kde γ reguluje šírku Gaussovskej krivky. Menšia hodnota znamená hladšiu rozhodovaciu hranicu, väčšia hodnota naopak členitejšiu [49][50].

$$K(x_i, x_j) = (x_i^T x_j)^d \quad (1.6)$$

$$K(x_i, x_j) = e^{-\gamma ||x_i - x_j||^2} \quad (1.7)$$

Castaño a spol. [52] vo svojej publikácii skúmajú klasifikáciu pomocou SVM do dvoch tried - normálne EKG a znečistené pohybovým artefaktom. Použité dátu boli získané v riadenom experimente podobne ako naše, skúmaná bola iba jedna pohybová aktivita a to pohyb hornými končatinami. Namerané dátu boli rozdelené na segmenty o dĺžke 1.2 sekundy, korešpondujúce s jedným úderom srdca. Skúmali SVM s lineárnym aj polynomiálnym jadrom, najlepšie výsledky dosiahli pomocou Gaussovského jadra. Kher a spol. [53] riešia problém klasifikácie rôznych pohybových aktivít - pohyby hornými končatinami, rotácie v páse a chôdza. Ich prístup je odlišný v tom, že na klasifikáciu pomocou SVM nepoužívajú nespracovaný EKG signál, ale z neho extrahované príznaky pomocou rôznych transformácií, napríklad vlnkovej transformácie. Pomocou Gaussovského jadra dosiahli presnosť 95 %, kvôli využitiu transformácií táto metóda nie je vhodná na klasifikáciu v reálnom čase.

1.7 Vyhodnotenie klasifikácie do viacerých tried

1.7.1 Matica zámen

Ako hlavnú metriku na vyhodnotenie úspešnosti klasifikácie sme zvolili maticu zámen, ktorá reprezentuje klasifikáciu do viacerých tried ako kontingenčnú tabuľku, kde riadky predstavujú

¹⁵V anglickom jazyku *soft margin*.

skutočnú hodnotu a stĺpce predikovanú hodnotu. Na diagonále sa nachádzajú správne predikcie, zatiaľ čo na ostatných pozíciach nesprávne. Hodnoty v jednotlivých poliach matice môžeme uvádzať v absolútном, alebo normalizovanom tvare, teda v percentuálnom podeli [54]. V našom prípade budeme kvôli nevyváženosti dátovej sady výsledky klasifikácie uvádzať spravidla v normalizovanom tvare.

		predikované hodnoty			
		TN	FP	TN	TN
skutočné hodnoty	FN	TP	FN	FN	
	TN	FP	TN	TN	
	TN	FP	TN	TN	

■ **Obr. 1.14** Matica zámen pre klasifikáciu do viacerých tried.

Maticu zámen interpretujeme v kontexte klasifikácie do viacerých tried z pohľadu jednej triedy x tak, ako je uvedené na obrázku 1.14.

- **TP (True positive)** - počet segmentov triedy x , ktoré boli správne klasifikované.
- **FN (False negative)** - počet segmentov triedy x , ktoré boli nesprávne klasifikované.
- **TN (True negative)** - počet segmentov triedy inej ako x , ktoré boli správne klasifikované.
- **FP (False positive)** - počet segmentov triedy inej ako x , ktoré boli nesprávne klasifikované.

V texte budeme tieto metriky ďalej uvádzať iba pomocou vyššie uvedených skratiek. Na základe hodnôt uložených v matici zámen vieme počítať ďalšie metriky, vybrané z nich zadefinujeme nižšie.

1.7.2 Accuracy

Presnosť, v anglickom znení *accuracy*, je definovaná ako podiel segmentov, ktoré model určil správne, voči celkovému počtu segmentov a dá sa vyjadriť vzťahom 1.8 [54].

$$ACC = \frac{TP + TN}{TP + TN + FP + FN} \quad (1.8)$$

1.7.3 Recall

Recall, alebo senzitivita, prípadne *true positive rate (TPR)*, je definovaný ako podiel segmentov vybranej triedy, ktoré model určil správne [54]. Dá sa vyjadriť vzťahom 1.9 a v normalizovanom tvare matice zámen leží senzitivita pre jednotlivé triedy na diagonále.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (1.9)$$

1.7.4 Precision

Precision, alebo *positive predictive value (PPV)*, je definovaná ako podiel segmentov označených ako patriacich do vybranej triedy, ktoré skutočne do tejto triedy patria a dá sa vyjadriť vzťahom 1.10 [54].

$$\text{Precision} = \frac{TP}{TP + FP} \quad (1.10)$$

1.7.5 F1 Score

F1 Score je metrika, ktorá počíta harmonický priemer *precision* a *recall* a je vhodná na vyhodnocovanie predikcií na nevyvážených dátach. Pre každú triedu zvlášť sa dá vyjadriť vzťahom 1.11 a následne sa v prípade klasifikácie do viacerých tried počíta vážený priemer získaných hodnôt podľa vzťahu 1.12 [54].

$$\text{F1 Score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (1.11)$$

$$\text{Weighted F1 Score} = \sum_{i=1}^N w_i \times \text{F1 Score}_i \quad (1.12)$$

..... Kapitola 2

Metodika experimentu

V tejto kapitole podrobne popíšeme priebeh riadeného experimentu uskutočneného so zámerom získania dát pre účely tejto práce. Taktiež popíšeme všetky potrebné zariadenia využité pri jednotlivých meraniach, ale aj vytvorené nástroje na vizualizáciu a kontrolu získaných EKG záznamov a ich následnú anotáciu. Cieľom experimentu bolo vyhotoviť dátovú sadu, vhodnú na použitie pri trénovaní a testovaní modelov umelej inteligencie, ktorých úlohou je detegovať pohybové artefakty s čo najväčšou presnosťou.

2.1 Popis subjektov

Ked'že v tejto práci neanalyzujeme EKG zo zdravotného hľadiska, v dátach nepredpokladáme veľkú interpersonálnu variabilitu čo sa týka výskytu pohybových artefaktov. Preto boli subjekty vyberané náhodne a neboli stanovené žiadne podmienky na účasť, okrem zdravotnej spôsobilosti vykonávať jednotlivé úkony v experimente. Jediné obmedzenie, a to aby boli subjekty v produktívnom veku, priamo vyplýva zo zamerania práce a využitia pre zásahové zložky. Interpersonálna variabilita z hľadiska priebehu EKG signálu je naopak žiadúca, ked'že detekcia by mala byť voči tejto variabilite odolná. Experimenty sme preto vykonávali na viacerých subjektoch.

Experimentu sa zúčastnilo 10 dobrovoľníkov, pričom 3 z nich boli ženského pohlavia a 7 mužského. Vekové rozmedzie subjektov bolo 21 - 42 rokov. Priemerná váha bola $67,67 \pm 9,53$ kg pre ženy a $81,29 \pm 7,99$ kg pre mužov, priemerná výška $171,33 \pm 6,34$ cm pre ženy a $181,71 \pm 5,67$ cm pre mužov. Tieto hodnoty sú primerané jednotlivým pohlaviam, nenachádzajú sa v nich žiadne extrémy, rovnako aj fyzická kondícia jednotlivých subjektov bola primeraná ich veku. Priemerná hodnota obvodu hrudníka bola $80 \pm 6,53$ cm pre ženy a $93 \pm 6,61$ pre mužov. Táto hodnota je u mužov výrazne vyššia ako u žien, čo je dôležitá informácia kvôli porovnaniu s najmenším možným nastavením obvodu hrudných pásov. Ked'že pri monitorovaní pomocou plošných suchých a textilných elektród je kľúčové zabezpečenie dostatočného kontaktu elektród s kožou, nastavenie pásu môže byť limitujúce pre osoby s úzkym hrudníkom.

■ **Tabuľka 2.1** Prehľad subjektov experimentu.

ID	Pohlavie	Vek	Výška (cm)	Váha (kg)	Obvod hrudníka (cm)
01	M	36	182	94	105
02	M	22	193	80	97
03	Ž	42	165	55	72
04	M	23	184	88	87
05	Ž	25	180	78	88
06	Ž	24	169	70	80
07	M	38	180	75	91
08	M	30	182	70	84
09	M	21	173	75	90
10	M	21	178	87	97

2.2 Použitý hardware

Na snímanie EKG bol použitý špecializovaný analógový front-end **AD8232** [55] od firmy Analog Devices, určený na precízne meranie biopotenciálov v prenosných a fitnes EKG. Na realizáciu meracieho modulu bolo zvolené prieplustné pásmo pre EKG signál v rozsahu 0,05 až 150 Hz a celkové zosilenie 500. Vďaka tomu sú prenášané všetky významné frekvencie v EKG signáli a kvalita signálu sa pri kľudovom snímaní blíži klinickému EKG. Okrem základnej analógovej pásmovej pripusti s uvedeným prieplustným pásmom nie je so signálom zámerne vykonávaná žiadna ďalšia analógová a následne ani číslicová filtrácia, zariadenie teda poskytuje hrubé dátá. Použité obvodové riešenie ďalej obsahuje zapojenie pre aktívnu referenčnú elektródu, ktoré pri trojelektródovom pripojení pacienta použitom v tejto práci zaistí zvýšenie činitelia potlačenia súfázového signálu (CMRR). Izolačné napätie obvodu je 7000 V, maximálny merací rozkmit amplitúdy vstupného EKG signálu je špička-špička 6 mV. Modul tiež disponuje digitálnymi signálovými vodičmi na indikáciu stavu pripojenia elektród. Digitalizácia výstupného analógového signálu je realizovaná 32 bitovým mikrokontrolérom rodiny AT SAMD 21 (architektúra Arm Cortex-M0), vybaveným firmware, ktorý zaistuje digitalizáciu EKG signálu z analógového front-endu pomocou vstavaného 12 bitového analógovo-digitálneho (AD) prevodníku, serializáciu signálu a následný prenos cez vstavané USB rozhranie do pripojeného PC. Ekvidistantné vzorkovanie EKG signálu je nastavené na frekvenciu 500 Hz, čím zodpovedá klinickým štandardom pre snímanie EKG signálu. Zariadenie je súčasťou experimentálneho systému na sledovanie vitálnych funkcií členov integrovaného záchranného systému (IZS), najmä hasičov, vyvájaného na Katedre informačných a komunikačných technológií v lekárstve FBMI ČVUT.

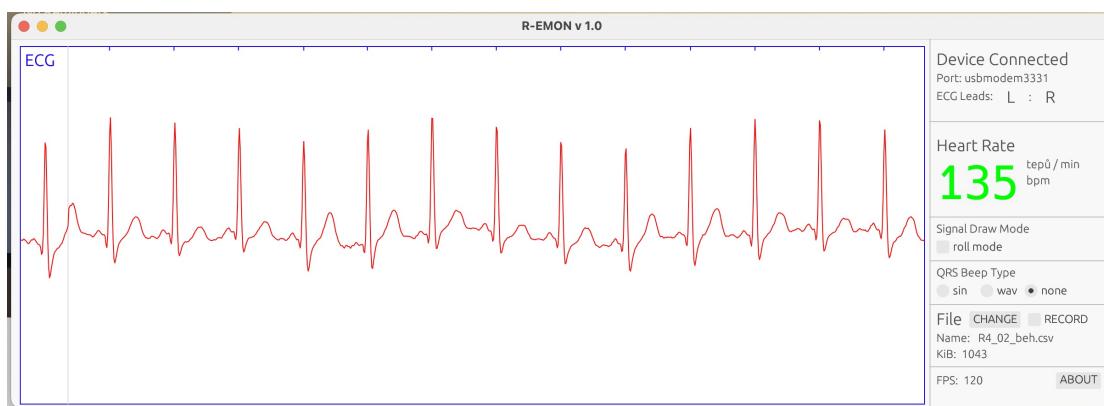


■ **Obr. 2.1** Vývojový modul s obvodom AD8232 [56].

2.3 Použitý software

2.3.1 Vizualizácia a záznam EKG

Software ju súčasťou vyššie popísaného hardwarového riešenia zariadenia na snímanie, digitálizáciu a prenos EKG. Umožňuje automatickú detekciu pripojeného EKG modulu, vyčítanie a vizualizáciu EKG dát v reálnom čase a ukladanie do súboru. Software umožňuje konfiguráciu počtov kanálov, ich rozsahov, úpravu komunikačného protokolu, robustnú detekciu R-vln v EKG signáli pomocou Hamilton-Tompkinsovho algoritmu a signalizáciu srdečného rytmu akustickým signálom. Software je implementovaný v programovacom jazyku Rust¹ a je súčasťou experimentálneho systému na snímanie biopotenciálov v teréne, uvedeného v predošej kapitole. Software je multiplatformný a umožňuje beh pod operačnými systémami MS Widnows, MacOS a Linux.



■ Obr. 2.2 Software na vizualizáciu a záznam EKG.

2.3.2 Manuálna anotácia dát

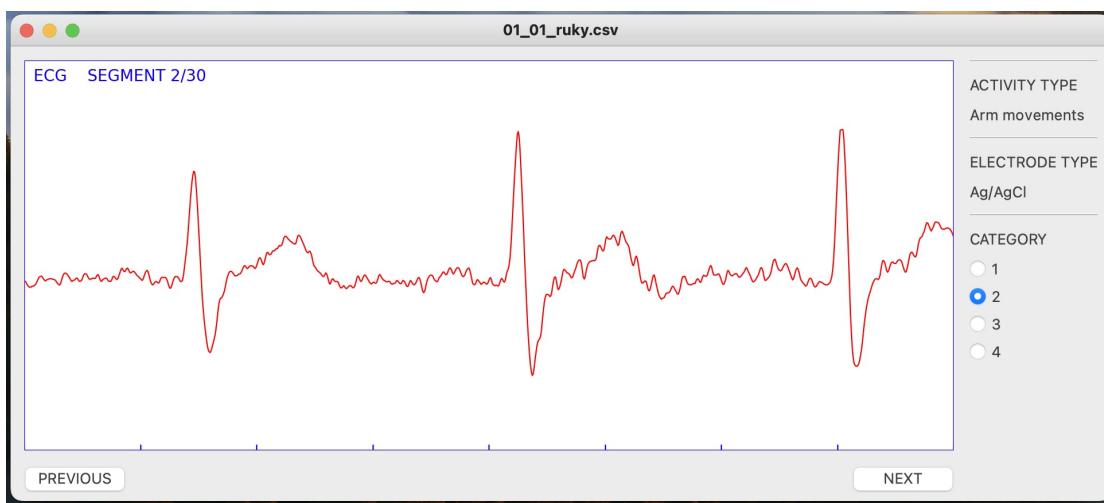
Kvôli nutnosti manuálne anotovať namerané EKG dáta bolo vytvorené jednoduché grafické rozhranie. Okrem samotnej anotácie dát toto rozhranie slúži aj na zobrazenie a kontrolu nameraných dát z jednotlivých experimentov. Zdrojový kód je napísaný v programovacom jazyku **Python 3.8**², s inými verziami nemusí byť plne kompatibilný. Užívateľské rozhranie bolo vytvorené pomocou **PyQt5**³, ktoré poskytuje programátorské rozhranie medzi knižnicou na tvorbu grafických aplikácií Qt a jazykom Python. EKG krivka je zobrazená na grafe vykreslenom pomocou knižnice **Matplotlib**⁴. Kompletný zoznam knižníc potrebných na spustenie aplikácie je možné nájsť v zložke so zdrojovými kódmi v súbore *requirements.txt*.

¹<https://www.rust-lang.org>

²<https://www.python.org>

³<https://pypi.org/project/PyQt5/5.8/>

⁴<https://matplotlib.org>



■ Obr. 2.3 Grafické rozhranie na manuálnu anotáciu EKG dát.

Grafické rozhranie umožňuje navigáciu cez jednotlivé segmenty EKG signálu, pričom ich dĺžka je voliteľná. Na pohyb medzi segmentmi sa dajú použiť bud' tlačidlá umiestnené pod oknom, v ktorom sa zobrazuje aktuálny segment, alebo ľavá a pravá šípka na klávesnici. V ľavom hornom rohu okna zobrazujúceho aktuálneho segmentu sa nachádza číslo aktuálneho segmentu a ich celkový počet. V paneli na pravej strane okna sa nachádza typ pohybovej aktivity a použitých elektród, oboje sú odvodené od názvu súboru. V neposlednom rade sa tu nachádzajú aj prepínacie tlačidlá, ktorými sa anotuje daný segment podľa rozličnej úrovne znečistenia pohybovým artefaktom. Tieto tlačidlá sa dajú opäť ovládať priamo kliknutím, alebo sa dá na ich prepínanie využiť medzerník na klávesnici. Pri otvorení vstupného súboru, ktorý chce používateľ anotovať, sa automaticky vytvorí výstupný *.csv* súbor, rovnako sa pri zmene stavu prepínacieho tlačidla označujúceho artefakt tento súbor automaticky prepíše, explicitné ukladanie nie je nutné.

Používateľské rozhranie je možné spustiť pomocou príkazu **python3 data_labeler.py** z príslušnej zložky, a voliteľné parametre sú nasledovné:

```
data_labeler.py [-l segment_length] [-f sampling_rate] [-s starting_segment] input_file
    input_file (str)           - názov vstupného súboru, musí byť súbor typu .csv
                                nachádzajúci sa v zložke /data
    segment_length (int)       - dĺžka segmentu v sekundách, predvolená na 5 sekúnd
    sampling_rate (int)        - vzorkovacia frekvencia vstupného súboru, predvolená na
                                500 vzoriek za sekundu
    starting_segment (int)     - číslo počiatočného segmentu na zobrazenie, predvolené na
                                prvý segment
```

2.4 Použité elektródy

Séria úkonov bola vykonávaná najskôr s gélovými elektródami, následne s hrudným pásmom s plošnými elektródami z nerezovej ocele (Obr. 2.4 dole) a na záver s hrudným pásmom s textilnými elektródami (Obr. 2.4 hore). Rozmery jednej elektródy z nerezovej ocele sú $6 \times 4,5$ cm a rozmery jednej textilnej elektródy 6×4 cm. Jednorazové Ag/AgCl elektródy boli použité konkrétnie EKG H34 SG KendallTM od firmy CovidienTM, obsahujúce hydrogél vhodný na dlhodobé monitorovanie. Oba hrudné pásy sú súčasťou vyššie uvedeného experimentálneho systému vyvíjaného na FBMI ČVUT.



■ **Obr. 2.4** Hrudný pás s elektródami z nerezovej ocele a textilnými elektródami.

Poradie elektród bolo zvolené tak, aby sme minimalizovali nutnosť prípravy pokožky subjektov. Keďže gélové elektródy obsahujú vodivú zložku, nie je potrebná žiadna ďalšia príprava pokožky. Elektródy z nerezovej ocele a textilné elektródy fungujú lepšie ak je subjekt trochu zahriaty a tým pádom spotený, keďže pot zvyšuje vodivé vlastnosti medzi kožou a elektródou. Nadmerné potenie môže viesť k vytvoreniu takzvaného potného mostíka, kedy dochádza k skratu elektród, prípadne výrazne zníženému odporu, následkom čoho je meraný EKG signál utlmený na takmer nemerateľný. Zvolené úkony však nepredstavovali takú záťaž, aby zapríčinili nadmerné potenie subjektov. V prípade, že subjekt nebol po prvej sérii úkonov dostatočne spotený, simulovali sme tento jav miernym zvlnčením pokožky v miestach dotyku elektród.

Keďže ide o terénné monitorovanie, umiestnenie elektród nebolo presne stanovené, ako pri štandardizovanom snímaní EKG signálu. Oba hrudné pásy boli umiestnené v oblasti pod prsným svalom a polohy gélových elektród kopírovali pozíciu suchých elektród na páse. Jedna elektróda bola umiestnená zhruba v strede hrudníka, ostatné dve symetricky na ľavej a pravej strane rebier. Dôležité pre kvalitu signálu bolo, aby sa elektródy nenachádzali pod úrovňou rebier. Ako nulová elektróda bola zvolená prostredná, ostatné dve boli aktívne. Napojením na nositeľný snímač bol takto vytvorený 1-zvodový systém na záznam EKG.

2.5 Priebeh experimentu

Po príchode na pracovisko bol každý subjekt oboznámený s priebehom a dĺžkou experimentu, a bol požiadaný o podpísanie informovaného súhlasu (Dodatok A). Subjekt bol informovaný o tom, že účasť na experimente je dobrovoľná, aj o možnosti kedykoľvek svoju účasť na experimente ukončiť, a to bez udania dôvodu. Taktiež bol informovaný o možnosti odmietnuť vykonávať akýkoľvek úkon v prípade, že by bol pre neho príliš fyzicky náročný. Následne bol každý subjekt požiadaný o vyplnenie dotazníku (Dodatok B), v ktorom sa zisťovali nasledovné údaje: meno, pohlavie, vek, výška, váha a obvod hrudníka. Dotazník obsahuje aj otvorenú časť týkajúcu sa pohybových obmedzení a ochorení kardiovaskulárneho a respiračného systému, ktoré by znemožňovali účasť v experimente. V kontexte dotazníka bol každý poučený, že záznamy, podľa ktorých je možné subjekt identifikovať, budú uschované ako dôverné dokumenty a nebudú verejne sprístupnené. Taktiež že v prípade, kedy budú výsledky štúdie publikované, jeho totožnosť nebude zverejnená. V informovanom súhlase bolo zdôraznené aj to, že zo získaných dát nebudú vyvodzované žiadne závery týkajúce sa zdravotného stavu.

Podpisom informovaného súhlasu a vyplnením dotazníku subjekt potvrdil, že sa ho netýkajú žiadne z nasledovných vylúčovacích kritérií. Fáza experimentu, ktorá zahŕňa fyzickú záťaž, vyžadovala vylúčenie osôb, ktoré trpia závažným ochorením respiračného alebo kardiovaskulárneho systému. Kvôli pohybu na bežiacom páse bolo potrebné z experimentu vylúčiť aj osoby trpiace zníženou pohyblivosťou, alebo zníženou funkciou rovnovážneho systému, a to aj v prípade zapríčinenia konzumáciou alkoholu, alebo inej omamnej látky. Dĺžka experimentu na jeden subjekt bola stanovená na 30 minút - 15 minút rezervovaných na samotné merania a zvyšných 15 minút na réziu spojenú s výmenou elektród a prechodom medzi jednotlivými pohybovými aktivitami. Je dôležité spomenúť, že dĺžka vykonávaného úkonu nebola vždy presne jedna minúta, ide o približný časový údaj. Napríklad pri postupnej zmene rýchlosťi pohybu na bežiacom páse bolo potrebné počkať na ustálenie rýchlosťi.

Poradie jednotlivých úkonov v rámci experimentu bolo stanovené tak, ako je uvedené v tabuľke 2.2. Takto stanovená séria úkonov bola vykonávaná tri krát, zakaždým s iným druhom elektród. Poradie úkonov bolo pre správnosť postupu zostavené tak, aby záťaž narastala, aj keď zvyšujúca sa srdcová frekvencia by nemala mať vplyv na výskyt pohybových artefaktov v zázname. Navyše mal medzi každou sériou úkonov subjekt možnosť oddýchnuť si počas výmeny elektród, ktorá trvala niekoľko minút, čo umožnilo klesnutie srdcovej frekvencie späť na takmer kľudovú pred začiatkom ďalšej série úkonov.

■ **Tabuľka 2.2** Poradie pohybových aktivít.

Pohybová aktivita	Doba merania vo formáte od - do (mm:ss)
Kľud	0:00 - 1:00
Pohyby hornými končatinami	1:00 - 2:00
Chôdza 4 km/h	2:00 - 3:00
Beh 8 km/h	3:00 - 4:00
Drepy	4:00 - 5:00

..... Kapitola 3

Dátová sada

V nasledujúcej kapitole opíšeme štruktúru vzniknutej dátovej sady. Dáta pre účastníkov experimentu sú členené do zložiek, pričom každý subjekt ma svoju vlastnú, ktorá obsahuje všetky zaznamenané EKG dátá a k ním príslušné anotácie segmentov. Experimentu sa zúčastnilo **10 subjektov**, pre každého je nameraných niekoľko záznamov dlhých približne jednu minútu - **5 rôznych fyzických aktivít** zaznamenaných pomocou **3 rôznych typov elektród**. Dostávame teda 15 záznamov pre každý subjekt, takže dokopy **150 minútových záznamov EKG**. Každý z týchto záznamov bol následne rozdelený na segmenty dlhé 2 sekundy, čím na záver získavame približne **4500 anotovaných segmentov**. Vzniknutá dátová sada je verejne dostupná pod GNU GPL 3.0 licenciou na GitHub repozitári Katedry informačných a komunikačných technológií v lekárstve FBMI ČVUT.

3.1 Anotácia dátovej sady

Významnou časťou práce bola anotácia vzniknutej dátovej sady. Po analýze viacerých možností sme sa rozhodli dátá anotovať do štyroch rôznych kategórií, pričom každá je definovaná charakteristickými vlastnosťami. Testovali sme aj možnosť kedy sme kategórie definovali podľa viditeľnosti jednotlivých vln, tento postup sa však kvôli interpersonálnej variabilite priebehu EKG signálu ukázal ako problematický, keďže nie každý subjekt mal v kľudovom zázname viditeľnú P-vlnu, rovnako amplitúda T-vlny sa výrazne líšila.

Dĺžka segmentu bola na základe vyššie uvedených publikácií zvolená ako 2 sekundy, pričom sme zvažovali čo najkratšiu dĺžku, aby bola zachovaná podmienka využitia v reálnom čase, a zároveň sme brali ohľad aj na časovú náročnosť anotácie. Na záver práce sa v rámci možných rozšírení riešenia budeme venovať aj možnosti dôkladnejšej anotácie. V jednom segmente sa môže vyskytovať viac ako jedna intenzita rušenia, pri anotácii sme sa rozhodovali podľa dominantnej intenzity. Aj keď sme sa snažili definovať kategórie tak, aby sa čo najmenej prekrývali, nie vždy sa striktne vzájomne vylučujú. Keďže segment obsahuje viac ako jeden srdečný cyklus, niektoré sa nachádzajú na pomedzí dvoch kategórií, čo môže mať vplyv na výsledky klasifikácie.

3.1.1 Artefakt kategórie 1

Srdečný rytmus čitateľný a zároveň všetky srdečné cykly tiež čitateľné. Aspoň jeden cyklus bez rušenia, spadajú sem dva charakteristické prípady:

- Žiadne rušenie, takýto segment je pri terénnom monitorovaní ojedinelý. (Obr. 3.1 hore).
- Minimálne rušenie, aspoň jeden srdečný cyklus úplne bez rušenia. Superponované rušenie má nízku amplitúdu, často ide o myopotenciály. (Obr. 3.1 dole).



■ **Obr. 3.1** Segmenty patriace do kategórie 1.

3.1.2 Artefakt kategórie 2

Srdečný rytmus čitateľný a aspoň jeden srdečný cyklus je čitateľný. Rušenie prítomné vo všetkých cykloch, amplitúda ani v jednom nepresahuje polovicu amplitúdy R-vlny.



■ Obr. 3.2 Segment patriaci do kategórie 2.

3.1.3 Artefakt kategórie 3

Srdečný rytmus čitateľný a zároveň ani jeden srdečný cyklus nie je čitateľný. Vznikajú falošné vlny, ktorých amplitúda presahuje polovicu amplitúdy R-vlny, často prítomné abrupty.

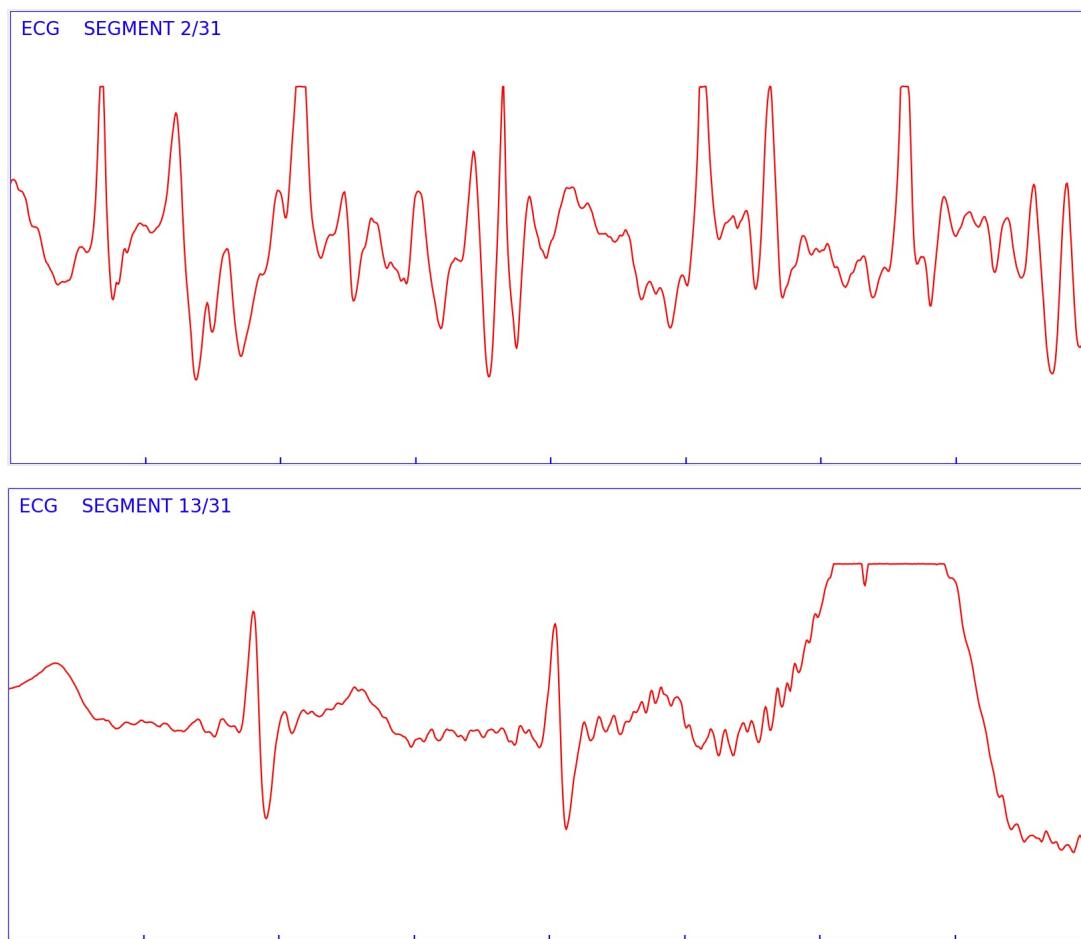


■ Obr. 3.3 Segment patriaci do kategórie 3.

3.1.4 Artefakt kategórie 4

Hlavným rozdielom oproti predošlým kategóriám je, že **srdečný rytmus nie je čitateľný**, prakticky sem spadajú dva rôzne prípady:

- Na celom signáli je superponované rušenie s amplitúdou, ktorá znemožňuje aj kvalitnému QRS detektoru správnu detekciu R-vln. Vznikajú falošné vlny so zameniteľnou amplitúdou mimo refraktérnej fázy detektoru, teda v oblasti koniec T-vlny - začiatok Q-vlny (Obr. 3.4 hore).
- Aspoň jedna nerozoznateľná R-vlna, často kvôli saturácii signálu. Takýto segment je z hľadiska analýzy spektra ľahko zameniteľný s nižšími kategóriami, keďže rušenie nie je prítomné po celú dobu (Obr. 3.4 dole).



■ Obr. 3.4 Segmenty patriace do kategórie 4.

3.2 Štruktúra dát

EKG signál je zaznamenaný do súboru, ktorý obsahuje iba dva stĺpce - jeden pre časový údaj a druhý pre hodnotu signálu v danom čase, jeho štruktúru je možné vidieť v tabuľke 3.1. Prvý aj druhý stĺpec obsahuje záznam vo forme časovej rady, v ukážke je zobrazených prvých 5 vzoriek záznamu.

■ **Tabuľka 3.1** Súbor s EKG záznamom.

timestamp	value
2024-03-26 15:04:53.249732	1698
2024-03-26 15:04:53.251727	1874
2024-03-26 15:04:53.253784	2021
2024-03-26 15:04:53.253784	2153
2024-03-26 15:04:53.257780	2291

Pre správnu anotáciu typu pohybovej aktivity a zobrazenie druhu elektród v grafickom rozhraní je potrebné dodržať predpísané názvoslovie vstupného súboru, ktoré je *ID_TYP-ELEKTRÓDY_TYP-AKTIVITY.csv*. Typ pohybovej aktivity je kódovaný podľa tabuľky 3.2, pričom neznáma hodnota sa uvádzá v prípade, že názov súboru na príslušnom mieste neobsahuje ani jednu z uvedených aktivít. Typ použitých elektród je kódovaný podľa tabuľky 3.3.

■ **Tabuľka 3.2** Kódovanie pohybovej aktivity.

Pohybová aktivity	Číselná hodnota
Kľudová fáza	0
Pohyby hornými končatinami	1
Chôdza 4 km/h	2
Beh 8 km/h	3
Drepy	4
Neznáma	-1

■ **Tabuľka 3.3** Kódovanie typu elektród.

Typ elektród	Číselná hodnota
Ag/AgCl	1
Chróm-niklel	2
Textil	3
Neznámy	-1

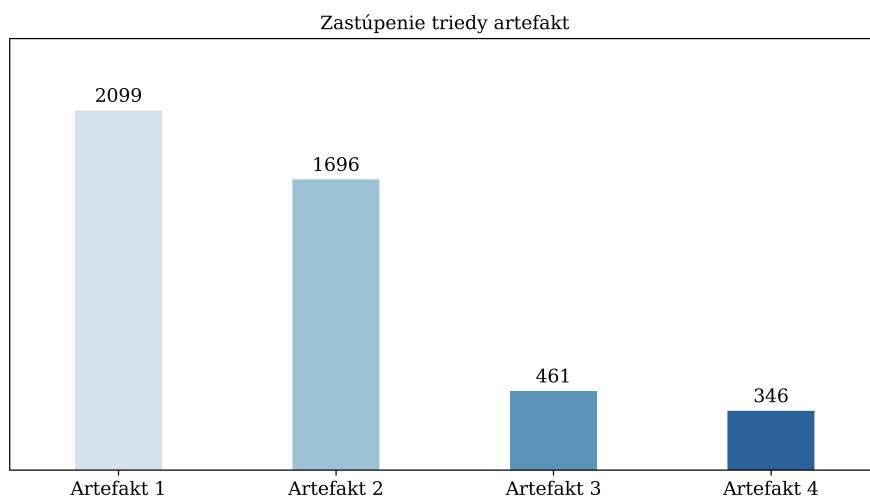
Názvoslovie súborov vytvorených pomocou grafického rozhrania na anotáciu dát je nasledovné - *ID_TYP-ELEKTRÓDY_TYP-AKTIVITY_DLŽKA-SEGMENTU.csv*. Dĺžka segmentu je v názve uvedená aby sa dali odlišiť anotácie vstupných súborov pre rôzne zvolené dĺžky segmentu. Súbory obsahujú stĺpec pre začiatok a koncovú pozíciu segmentu, typ aktivity, artefakt a typ elektródy, ich štruktúra je zobrazená v tabuľke 3.4.

■ **Tabuľka 3.4** Výstupný súbor s anotovanými dátami.

start	end	activity	artefact	electrode
0	1000	1	1	1
1000	2000	1	1	1
2000	3000	1	2	1
3000	4000	1	2	1
4000	5000	1	3	1
5000	6000	1	4	1

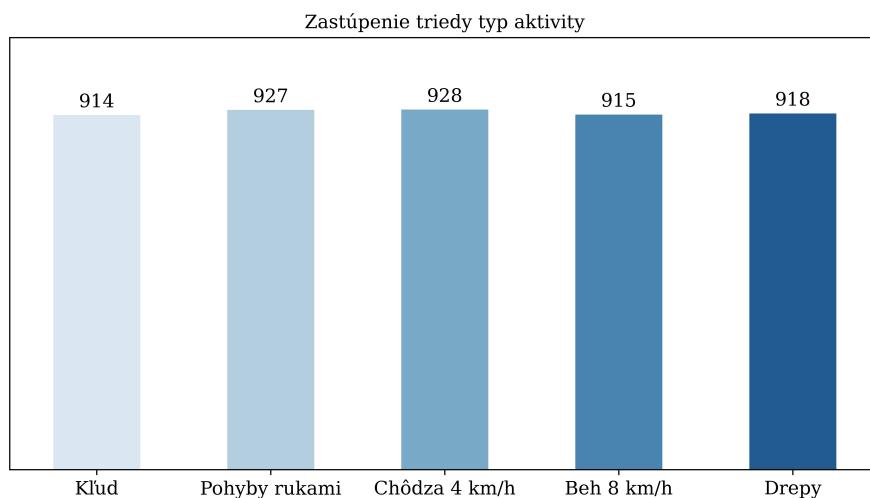
3.3 Zastúpenie tried

Po rozdelení surových dát na 2-sekundové segmenty sme dostali konečnú veľkosť dátovej sady - **4602 segmentov**. Ked'že nevyvážené zastúpenie tried v dátovej sade môže mať vplyv na výsledky klasifikácie, v krátkosti sme sa pozreli na ich distribúciu. Z hľadiska tried pohybových artefaktov je dátová sada výrazne nevyvážená, pričom s narastajúcou intenzitou artefaktu zastúpenie tried klesá. Celkové počty segmentov patriacich do jednotlivých kategórií je možné vidieť na grafe 3.5.

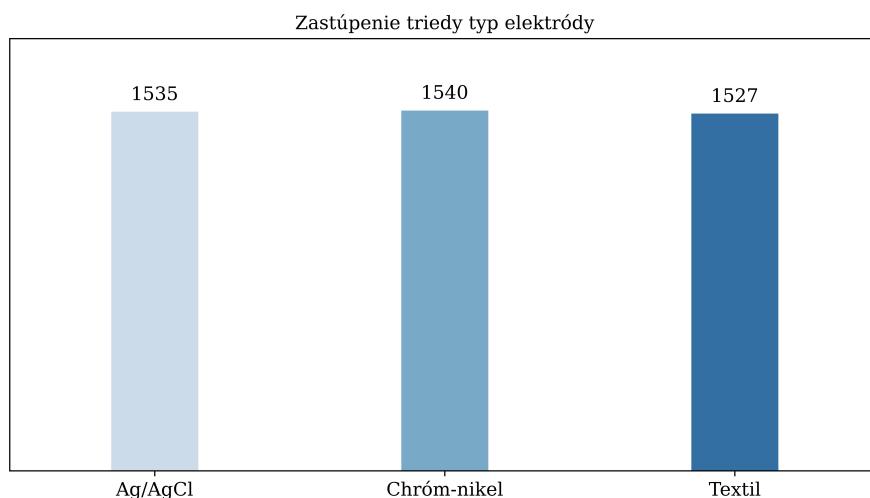


■ **Obr. 3.5** Počty segmentov podľa typu artefaktu.

Z hľadiska výskytu rôznych aktivít a elektród je dátová sada vyvážená, čo vyplýva zo samotnej metodiky experimentu. Pre každý subjekt boli zaznamenané všetky typy aktivít po dobu približne jednej minúty, pomocou troch rôznych druhov elektród, čím sme zaistili rovnomernú distribúciu týchto tried. Konkrétnie počty segmentov pre jednotlivé typy aktivít je možné vidieť na grafe 3.6 a pre typy elektród na grafe 3.7.



■ Obr. 3.6 Počty segmentov podľa typu aktivity.



■ Obr. 3.7 Počty segmentov podľa typu elektródy.

3.4 Predspracovanie dát

Ked'že jedným z cieľov práce je nájsť riešenie na rozpoznávanie pohybových artefaktov také, aby bolo využiteľné v reálnom čase, jednou z požiadaviek na riešenie je rýchle spracovanie analyzovaného segmentu. Preto sme v rámci predspracovania dát pristúpili iba k normalizácii - tá je nevyhnutná, ak chceme, aby bol model využiteľný aj na dátá namerané iným snímačom, ktorý nemusí nutne disponovať rovnakým AD prevodníkom. Ked'že poskytnutý nositeľný snímač EKG využíva 12 bitový AD prevodník, dátá boli normalizované na rozsah 0 až 4095. Následne bola z normalizovaných EKG záznamov pre každý segment pomocou rýchlej Fourierovej transformácie extrahovaná frekvenčná zložka v podobe amplitúdového spektra.

Kapitola 4

Výsledky

Kapitola je členená podľa jednotlivých dielčích výstupov práce. Na začiatok sa v krátkosti pozrieme na vyhodnotenie typov elektród a ich vhodnosť na terénné monitorovanie, následne výsledky klasifikácie aktivít, a na záver sa pozrieme na hlavný výstup práce a to výsledky klasifikácie pohybových artefaktov. Všetky modely boli implementované pomocou voľne dostupnej knižnice **Keras**¹, ktorá beží nad knižnicou **TensorFlow**² a poskytuje rozhranie na tvorbu a trénovanie modelov strojového učenia v jazyku Python. Trénovanie prebiehalo lokálne na stroji MacBook Pro 2019 s procesorom 2,4 GHz Quad-Core Intel Core i5 a 16 GB LPDDR3 RAM pamäťou. Na sledovanie výsledkov sme využili nástroj **Neptune**³, ktorý poskytuje grafické rozhranie na zaznamenávanie priebehu trénovania v reálnom čase.

4.1 Vyhodnotenie typu elektród

■ **Tabuľka 4.1** Podiel artefaktov podľa typu aktivity a typu elektródy.

		Kľud			
		1	2	3	4
Ag/AgCl	99,7	0,0	0,0	0,3	
Chróm-nikel	99,7	0,3	0,0	0,0	
Textil	100,0	0,0	0,0	0,0	

	Ruky				Chôdza			
	1	2	3	4	1	2	3	4
Ag/AgCl	23,3	76,4	0,0	0,3	20,1	32,0	20,7	27,2
Chróm-nikel	16,8	80,3	0,0	2,9	79,7	19,3	0,0	1,0
Textil	14,9	65,0	7,8	12,3	98,7	0,7	0,0	0,6

¹<https://keras.io>

²<https://www.tensorflow.org>

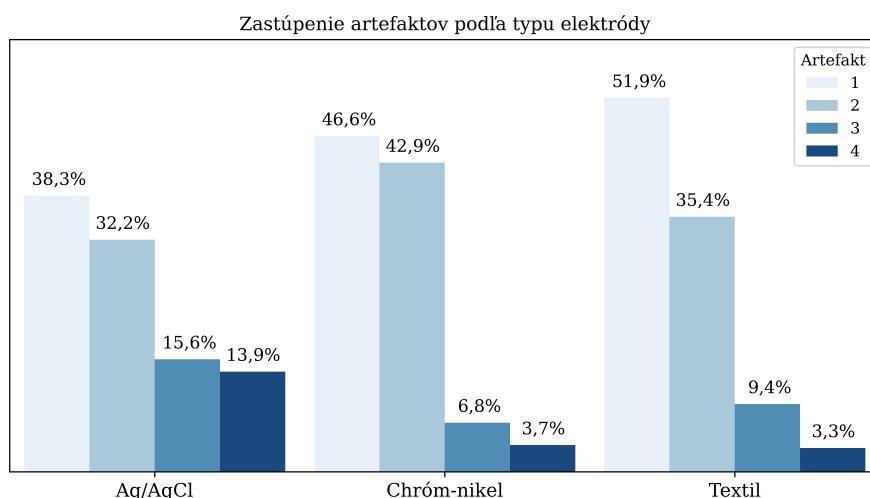
³<https://neptune.ai>

	Beh				Drepy			
	1	2	3	4	1	2	3	4
Ag/AgCl	0,0	10,2	39,3	50,5	48,7	41,6	9,7	0,0
Chróm-nikel	0,0	57,7	30,6	11,7	36,8	57,0	3,3	2,9
Textil	0,0	69,5	28,5	2,0	46,2	41,6	10,9	1,3

V tabuľke 4.1 môžeme vidieť percentuálny podiel tried pohybových artefaktov, pre jednotlivé typy elektród, rozdelený podľa aktivít. V kľudovej fáze boli takmer všetky segmenty s výnimkou dvoch klasifikované ako obsahujúce minimálne až žiadne rušenie. Pri pohybe hornými končatinami a drepoch a meraním pomocou Ag/AgCl elektród bol najväčší podiel segmentov klasifikovaný ako trieda 1 (23,3 % pri pohybe hornými končatinami a 48,7 % pri drepoch) a najmenší podiel ako trieda 4 (0,3 % pri pohybe hornými končatinami a 0,0 % pri drepoch), kvôli čomu dopadli spomedzi testovaných elektród najlepšie. Dôvodom je pravdepodobne to, že tieto elektródy sú priamo nalepené na koži, naroďaj od ostatných dvoch, ktoré sú upevnené pásom - vďaka tomu sa vedia lepšie vysporiadať s pohybmi v trupe.

Pri textilných elektródach a pohybových aktivitách chôdza a beh bol najväčší podiel segmentov klasifikovaný ako trieda 1 prípadne 2 (98,7 % pri chôdzi a 69,5 % pri behu) a najmenší podiel ako trieda 4 (0,6 % pri chôdzi a 2,0 % pri behu). Ani jeden segment obsahujúci záznam behu neboli klasifikovaný ako trieda 1, čo znamená, že tento typ aktivity je najnáročnejší na správne záhytenie. V prípade behu a chôdze vzniknuté artefakty nie sú spôsobené pohybom v oblasti trupu, ale prevažne rytmickými nárazmi. Zatiaľ čo rozdiel medzi jednotlivými elektródami pri pohybe hornými končatinami a drepoch neboli až taky výrazné, Ag/AgCl elektródy pri chôdzi a behu zaostávajú o desiatky percent, čo má veľký vplyv na finálne výsledky.

Na grafe 4.1 môžeme vidieť celkové výsledky, v ktorých si Ag/AgCl elektródy výrazne pohoršili a dopadli viditeľne najhoršie - najnižší podiel segmentov bol klasifikovaný ako trieda 1 a najvyšší ako trieda 4. V oboch prípadoch ide o rozdiel väčší ako 10 % oproti ostatným dvom typom elektród. Chróm-niklové a textilné elektródy dopadli podobne, pričom textilné elektródy dosiahli lepší výsledok pri triede 1, kde predbehli chróm-niklové o 5,3 %. Z porovnania elektród vyplýva, že najodolnejšie voči pohybovým artefaktom sú textilné elektródy, pričom práve tento typ hodnotili aj subjekty experimentu ako najkomfortnejší.



■ Obr. 4.1 Podiel artefaktov podľa typu typu elektródy.

4.2 Klasifikácia pohybových aktivít

Po všeobecnom predspracovaní dát, popísanom v predošej kapitole, spočívala príprava dát na trénovanie modelu v rozdelení dátovej sady na trénovaciu, testovaciu a validačnú množinu, pričom dáta boli rozdelené v pomere 80 % - 20 % - 10 %. Trénovacia množina bola použitá na trénovanie modelu, validačná na ladenie hyperparametrov a sledovanie priebehu trénovania. Testovacia množina bola použitá striktne iba na finálne vyhodnotenie. Dáta boli rozdelené pomocou stratifikovaného výberu, aby rozdelenie vo všetkých troch množinách zodpovedalo pomeru výstupnej triedy v dátach.

4.2.1 Model

Architektúru výsledného modelu je možné vidieť na obrázku 4.2, ide o hlboký konvolučný model s nasledovnými vstupmi a výstupmi:

- **Vstupy:** Časová a frekvenčná zložka EKG signálu.
- **Výstupy:** Vektor pravdepodobnosti príslušnosti k jednotlivým triedam, rozmer ktorého je definovaný počtom pohybových aktivít.

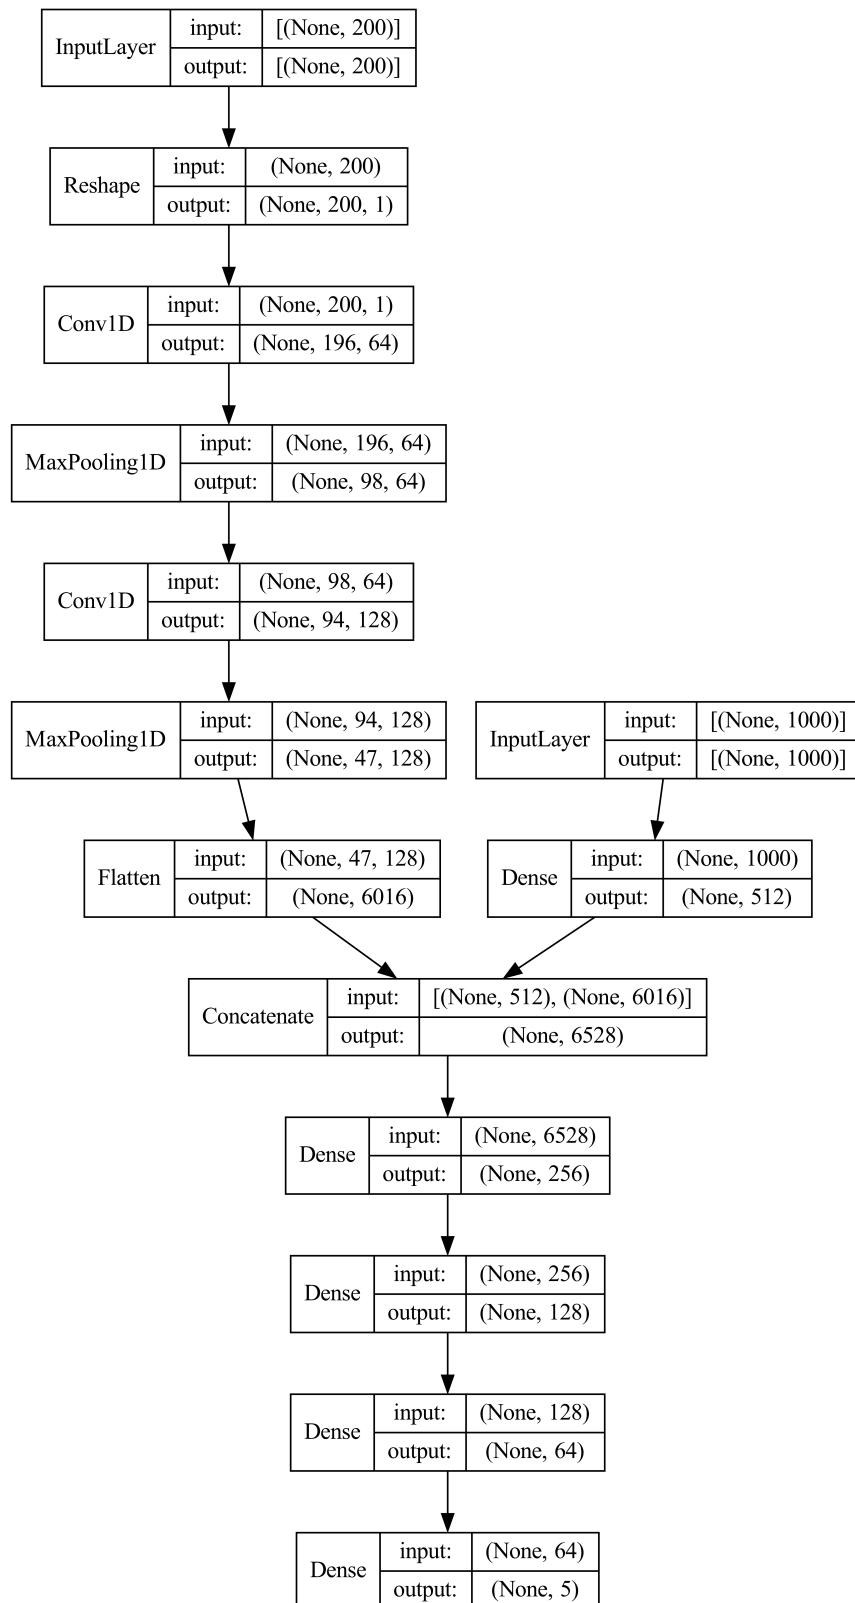
Kvôli klasifikácii do viacerých tried je na výstupnej vrstve použitá aktivačná funkcia *softmax* 1.3, takže výstupné neuróny obsahujú pravdepodobnosti príslušnosti k jednotlivým triedam. Cieľová premenná musela byť pomocou one-hot kódovania prevedená do rovnakého tvaru, finálne predikcie sú získavané funkciou *argmax*. Ako aktivačná funkcia v skrytých vrstvách bola zvolená *ReLU*, použitie ktorej je štandardom v hlbokých konvolučných architektúrach, lebo je efektívna na výpočet a dokáže predchádzať miernucemu gradientu. Model bol trénovaný pomocou optimalizačného algoritmu Adam a ako stratová funkcia pre klasifikáciu do viacerých tried bola zvolená *kategórická krížová entropia* 1.4.

Základnú architektúru sme hľadali empiricky - začali sme jednoduchou architektúrou s troma plne prepojenými vrstvami, ich počet sme postupne zvyšovali až kým nedošlo k preučeniu modelu a presnosť klasifikácie na validačnej množine prestala rásť. Z hľadiska rozmerov plne prepojených vrstiev sme najlepšie výsledky dosiahli ich postupným zmenšovaním, pričom takýto model vykonáva downsampling operáciu na vstupných dátach.

Následne sme skúmali vplyv jednotlivých vstupov modelu na úspešnosť klasifikácie. Na samom začiatku sme na vstup modelu dávali iba EKG segmenty, teda časovú zložku dát. Pri najlepšej nájdenej hľbokej architektúre sme dokázali týmto prístupom dosiahnuť presnosť iba 40 % na validačnej množine. Po modifikácii tej istej architektúry tak, aby na vstup brala aj frekvenčnú zložku dát, presnosť narásťla na 64 % na validačnej množine.

Skúšali sme rozličné dĺžky frekvenčného spektra, pričom sme boli z hora obmedzení hodnotou 250, ktorá vyplýva z Nyquist-Shannonovho teóremu a vzorkovacej frekvencie 500 Hz. Zistili sme, že dĺžka nad 200 Hz už neprinášala do modelu žiadnu užitočnú informáciu. Taktiež odstránenie jednosmernej zložky z EKG signálu nemalo vplyv na kvalitu klasifikácie. Posledný prístup, ktorý sme z hľadiska vstupov skúmali, bolo pridanie informácie o použitom type elektródy, tá však tiež neprinášala modelu žiadnu užitočnú informáciu.

Následným pridaním jedno-dimenziorných konvolučných vrstiev na spracovanie frekvenčnej zložky úspešnosť klasifikácie narásťla na 77 %. Z hľadiska konvolučných vrstiev sme skúšali rozličné počty od 1 až po 5, počty filtrov od 16 po 256, najlepšie výsledky sme dosiahli pre dve po sebe idúce vrstvy s 64 a 128 filtriemi, a následnými max poolingovými vrstvami.



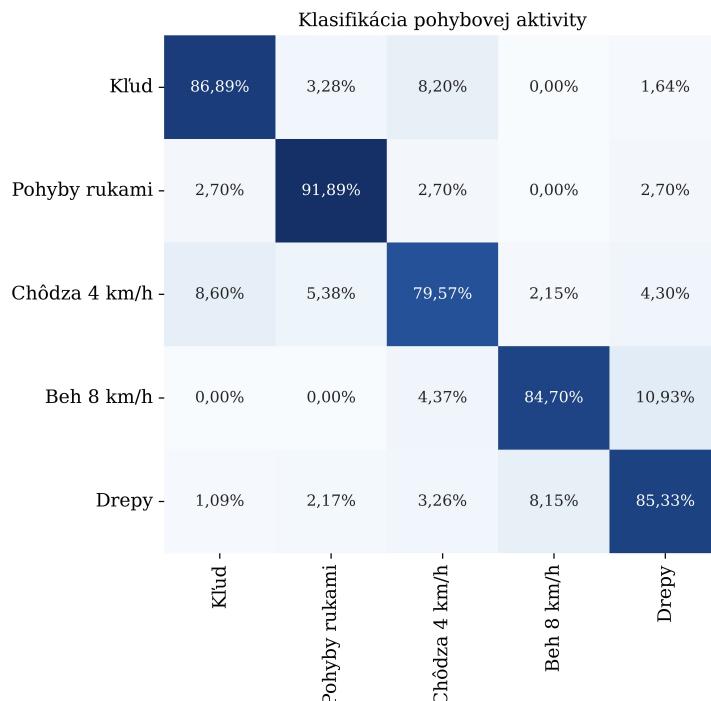
■ Obr. 4.2 Výsledný model pre klasifikáciu pohybových aktivít.

V priebehu experimentov boli pomocou metódy každý s každým ladené nasledovné hyperparametre a ich hodnoty, **najlepšia nájdená kombinácia je zvýraznená**. Keďže táto metóda je výpočtovo náročná, hľadali sme iba v okolí odpozorovaných hodnôt s dobrými výsledkami v experimente.

batch size	- 8, 16
learning rate	- 0.005, 0.001, 0.0005 , 0.0001
dropout	- 0,0 , 0.1, 0.2, 0.3, 0.4, 0.5
weight decay	- 0,0 , 0.001, 0.0001
kernel size	- 3, 5 , 9
pool size	- 2 , 3

Model bol trénovaný po dobu 15 epoch, z grafov vývoju metrik straty a presnosti bolo viditeľné, že dlhšie trénovanie neprináša ďalšiu informáciu. Zároveň ale validačná strata a presnosť modelu nezačali divergovať, takže skôr zastavenie nebolo potrebné. Po nájdení finálnej architektúry a vyladení hyperparametrov sme ešte skúšali natrénovať niekoľko modelov na náhodných podmnožinách dát a predikcie spriemerovať - prístup známy ako ensemble metóda *bagging*. Skúšali sme trénovať 5 až 10 modelov na podmnožinách veľkých 50 % - 80 %, výsledky klasifikácie to však nezlepšilo. Na trénovanie výsledného modelu boli použité aj validačné dátá.

4.2.2 Vyhodnotenie klasifikácie



■ Obr. 4.3 Matica zámen pre klasifikáciu pohybových aktivít.

Na obrázku 4.3 môžeme vidieť výslednú maticu zámen pre klasifikáciu pohybových aktivít do jednotlivých tried. Celková presnosť, ktorú sme na testovacej množine dosiahli, je **85,67 %**.

Táto hodnota je relatívne vysoká vzhládom na variabilitu EKG záznamov v rámci jednej triedy, keďže boli zaznamenané troma rôznymi elektródami s rozličnými vlastnosťami. Z tabuľky 4.1 uvedenej pri vyhodnotení elektród je vidieť, že pre každú aktivitu, okrem kľudu, obsahujú záznamy rozličné úrovne rušenia. Napriek tomu si s touto variabilitou model do veľkej miery dokázal poradiť.

4.3 Klasifikácia pohybových artefaktov

Ked'že vstupné dátá pre oba problémy sú rovnaké a výstupy sa líšia iba v počte tried, predpokladali sme, že výsledné architektúry jednotlivých modelov by mohli byť podobné. Navrhovať architektúru modelu sme začali na probléme klasifikácie aktivít, keďže ten má presne zadefinované triedy, a následne sme sa pri klasifikácii pohybových artefaktov odrazili od vzniknutého modelu. Dátá boli rovnako ako pri klasifikácii pohybových aktivít rozdelené na trénovaciu, testovaciu a validačnú množinu v pomere 80 % - 20 % - 10 %. Jediným rozdielom bolo, že množiny sme delili pomocou stratifikovaného výberu vzhládom k triede pohybových artefaktov.

Kvôli zisteniu, že dátová sada je nevyvážená z hľadiska pohybových artefaktov, sme vytvorili pomocou náhodného prevzorkovania vyváženú dátovú sadu, vzhládom k najpočetnejšej triede. Prevzorkovanie sme vykonávali až po rozdelení dát na trénovaciu a testovaciu množinu, aby sme sa vyhli duplikovaniu segmentov z trénovacích dát do testovacích. Sofistikovanejšie techniky prevzorkovania dátovej sady, ako napríklad SMOTE, neprichádzali do úvahy, lebo do dátovej sady zavádzajú šum, ktorý pri pohybových artefaktoch nesie dôležitú informáciu.

4.3.1 Model

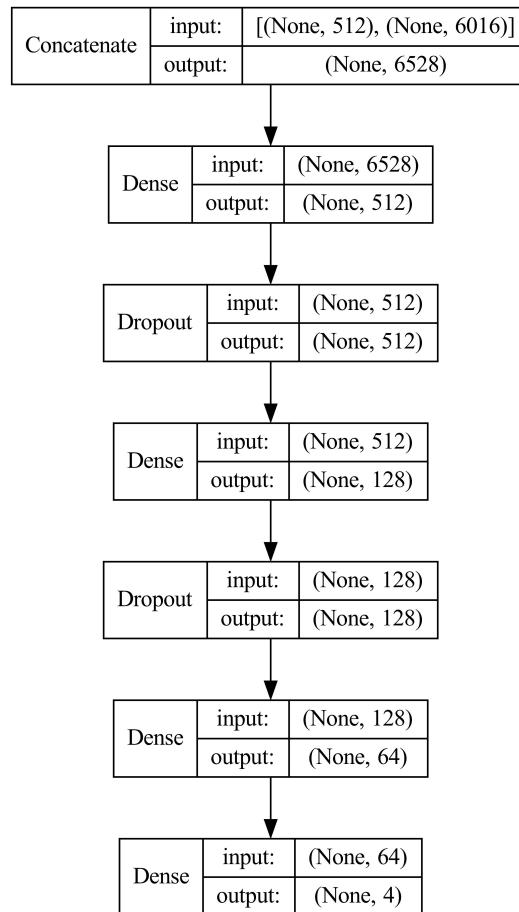
Architektúra výsledného modelu je takmer rovnaká ako 4.2, lísi sa až v časti po spojení časového a frekvenčného vstupu, na obrázku 4.4 je preto uvedená architektúra až od tohto bodu. Rozdielom je využitie *dropout* vrstiev, vstupy a výstupy sú nasledovné:

- **Vstupy:** Časová a frekvenčná zložka EKG signálu.
- **Výstupy:** Vektor pravdepodobnosti príslušnosti k jednotlivým triedam, rozmer ktorého je definovaný počtom tried pohybových artefaktov.

Na výstupnej vrstve je opäť použitá aktivačná funkcia *softmax* 1.3, a cieľová premenná musela byť pomocou one-hot kódovania prevedená do rovnakého tvaru. Aktivačná funkcia *ReLU* v skrytých vrstvých, optimalizačný algoritmus Adam a stratová funkcia *kategorická krížová entrópia* 1.4 zostali oproti predošlému modelu nezmenené.

Rovnako ako pri modeli na klasifikáciu pohybových aktivít sme z hľadiska vstupov skúšali zvýšiť dĺžku frekvenčného spektra, odstrániť jednosmernú zložku, a skúsiť pridať na vstup typ použitých elektród, opäť nič neprinieslo modelu užitočnú informáciu. Skúšali sú model trénovať aj na vyváženej dátovej sade vygenerovanej pomocou náhodného prevzorkovania, tento prístup však nemal žiadny vplyv na predikciu minoritných tried 3 a 4.

Z hľadiska architektúry pridávanie plne prepojených vrstiev nemenilo presnosť predikcií modelu, odoberanie presnosť zhoršovalo, a ani zmeny v konvolučnej časti modelu nezlepšovali predikcie. Skúšali sme aj variantu, kedy sme časovú aj frekvenčnú zložku paralelne spracovávali konvolučnými vrstvami a získané aktivačné mapy nakoniec spojili do plne prepojených vrstiev, takýto prístup však dosahoval horšie výsledky ako súčasná najlepšia nájdená architektúra.

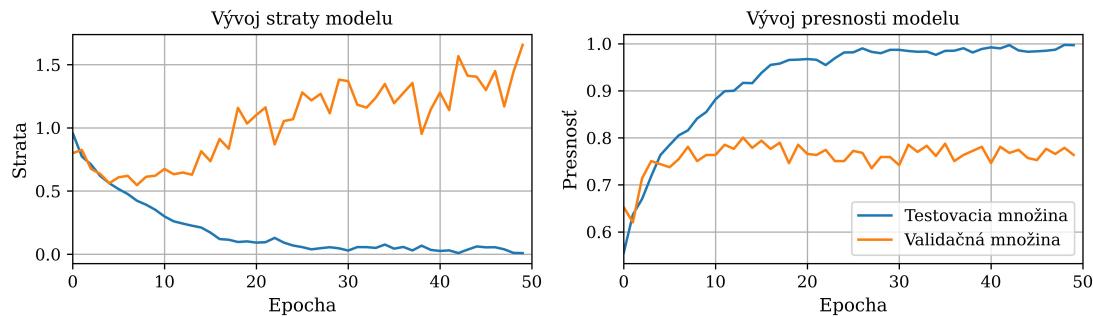


■ Obr. 4.4 Výsledný model pre klasifikáciu pohybových artefaktov.

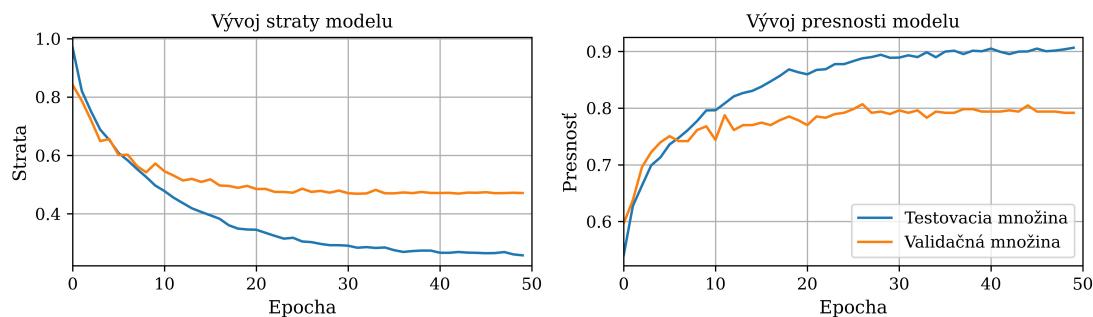
Z grafov vývoja metrík straty a presnosti počas trénovania 4.5 je viditeľné, že model je náchylný na preučenie - trénovacia a validačná krivka začali po zopár epochách divergovať. Z metód, ktoré by mohli s týmto problémom pomôcť sme skúšali batch normalizáciu, kedy sme normalizovali výstupy všetkých plne prepojených vrstiev, tá však nepomohla. Zmierniť tento problém sa nám podarilo pridaním *dropout* vrstiev medzi plne prepojené vrstvy, tie náhodne vynulujú niektoré neuróny počas trénovania. Pomohlo aj pridanie slabej L2 regularizácie, ktorá penalizuje kvadratiky váh, ako parameter optimalizačného algoritmu Adam.

Hlavné zlepšenie viditeľné na grafoch 4.6 sme dosiahli použitím plánovača *learning rate*. Na začiatku definovaná hodnota sa v každej epoche exponenciálne znižuje podľa vzťahu 4.1, kde $k=0,1$ je voliteľný parameter. Okrem výrazného potlačenia divergencie trénovacej a validačnej straty sa nám podarilo aj stabilizovať priebeh trénovania.

$$lr = lr \cdot e^{(-k) \cdot epoch} \quad (4.1)$$



■ Obr. 4.5 Priebeh vývoju straty a presnosti modelu pred použitím plánovania *learning rate*.



■ Obr. 4.6 Priebeh vývoju straty a presnosti modelu po použití plánovania *learning rate*.

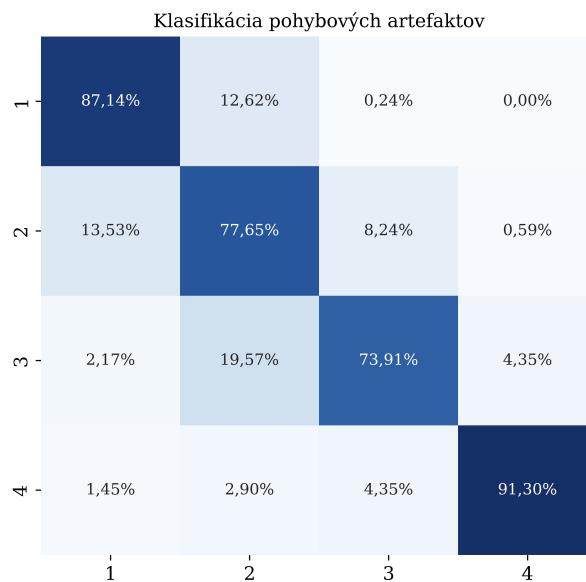
Model bol trénovaný po dobu 50 epoch, aj keď z grafov vývoju metrík straty a presnosti počas trénovania bolo viditeľné, že strata aj presnosť modelu sa po zhruba 30 epochách ustálili. Zároveň ale nezačali divergovať, takže skoré zastavenie nebolo potrebné.

V priebehu experimentov boli znova ladené tie isté hyperparametre a ich hodnoty, **najlepšia nájdená kombinácia je zvýraznená**.

batch size	- 8, 16
learning rate	- 0.005, 0.001, 0.0005, 0.0001
dropout	- 0.0, 0.1 , 0.2, 0.3, 0.4, 0.5
weight decay	- 0.0, 0.001, 0.0001
kernel size	- 3, 5 , 9
pool size	- 2 , 3

Rovnako ako pri modeli na klasifikáciu pohybových aktivít sme skúšali predikovať hodnoty pomocou ensemble metódy *bagging*, pričom jednotlivé modely boli trénované na podmnožinách dát veľkých 50 % - 80 %, ani v tomto prípade sme nezaznamenali žiadен nárast presnosti predikcií. Na trénovanie výsledného modelu boli použité aj validačné dáta.

4.3.2 Vyhodnotenie klasifikácie



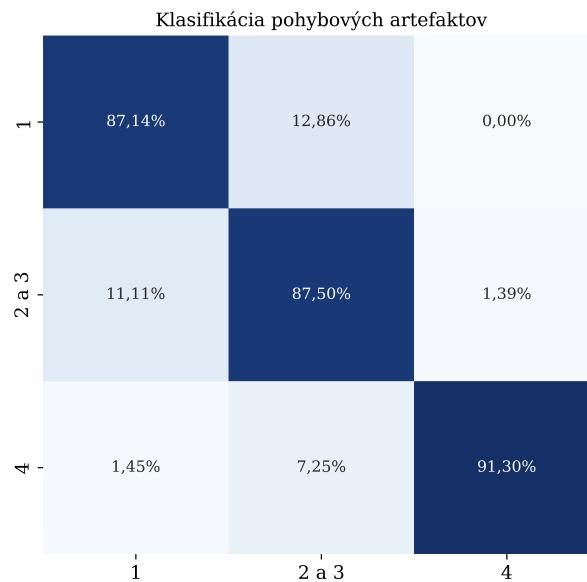
■ Obr. 4.7 Matica zámen pre klasifikáciu pohybových artefaktov.

Na obrázku 4.7 môžeme vidieť maticu zámen pre klasifikáciu pohybových artefaktov do štyroch tried. Výsledná presnosť na testovacej množine je **82,63 %** a hodnota *F1 Score* **82,68 %**. To, že sú hodnoty týchto dvoch metrík takmer rovné, potvrdzuje vyššie uvedené zistenie, že použitie dátovej sady s vyváženým zastúpením tried neprinieslo modelu žiadnu užitočnú informáciu. Aj keď bol model trénovalý na nevyváženej dátovej sade, naučil sa rovnako dobre predikovať minoritné aj majoritné triedy.

Kým trieda 4 je jasne zadefinovaná nečitateľnosťou srdečného rytmu, rozdiely medzi ostatnými troma triedami sú menej výrazné, čo potvrdzujú aj nasledujúce výsledky. *Precision* a *recall* pre jednotlivé triedy je možné vidieť v tabuľke 4.2. Z tabuľky je zjavné, že model má najväčší problém s klasifikáciou tried 2 a 3. Zároveň môžeme v matici zámen vidieť, že model najčastejšie zamieňal predikcie pre triedy 1 a 2 a pre triedy 2 a 3.

■ Tabuľka 4.2 *Precision* a *recall* pre klasifikáciu pohybových artefaktov.

Artefakt	<i>Precision (%)</i>	<i>Recall (%)</i>
1	88,20	87,14
2	78,34	77,65
3	68,00	73,91
4	91,30	91,30



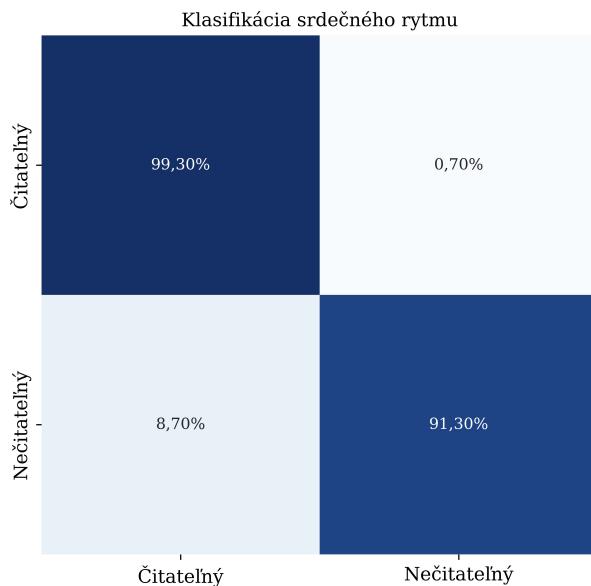
■ **Obr. 4.8** Matica zámen pre klasifikáciu pohybových artefaktov po zlúčení tried 2 a 3.

Zlúčením predikcií pre triedy 2 a 3 sa celkové výsledky výrazne zlepšili, ako je vidieť v matici zámen na obrázku 4.8. Presnosť aj *F1 score* na testovacej množine narastli na **87,62 %**, hodnoty metrií *precision* a *recall* pre jednotlivé triedy je možné vidieť v tabuľke 4.3. Takéto zlúčenie tried má aj praktický zmysel. V triede 1 sú obsiahnuté segmenty, ktoré sa dajú v praxi využiť na získanie srdečného rytmu aj interpretáciu EKG krivky, trieda 4 obsahuje segmenty, ktoré môžeme úplne odstrániť, lebo z hľadiska interpretácie EKG záznamu neposkytujú žiadnu informáciu. Zlúčená prostredná trieda takto obsahuje segmenty, ktoré sa dajú použiť na detekciu srdečného rytmu, iné charakteristiky z nich už však nemusia byť čitateľné.

■ **Tabuľka 4.3** *Precision a recall* pre klasifikáciu pohybových artefaktov po zlúčení tried 2 a 3.

Artefakt	<i>Precision (%)</i>	<i>Recall (%)</i>
1	88,20	87,14
2 a 3	86,50	87,50
4	91,30	91,30

Ďalšou dôležitou informáciou je, ako dobre dokáže model odlišiť segmenty, v ktorých je srdečný rytmus čitateľný, od segmentov, v ktorých nie je. Takto zadefinované kategórie predstavujú dva extrémy, ktoré môžu v dátach nastať, a je dôležité, aby ich model vedel správne odlišiť. Maticu zámen pre tieto dve triedy je možné vidieť na obrázku 4.9. Po zlúčení predikcií pre triedy, v ktorých je srdečný rytmus čitateľný, dostávame výslednú presnosť a *F1 Score* **98,70 %** na testovacej množine. Záverom teda je, že model dokáže tieto dve triedy odlišiť takmer vo všetkých prípadoch, pričom hodnoty *precision* a *recall* v tabuľke 4.4 ukazujú, že model častejšie nesprávne predikuje nečitateľný rytmus, než čitateľný.



■ **Obr. 4.9** Matica zámen pre klasifikáciu čitateľnosti srdečného rytmu.

■ **Tabuľka 4.4** *Precision a recall* pre klasifikáciu čitateľnosti srdečného rytmu.

Srdečný rytmus	<i>Precision (%)</i>	<i>Recall (%)</i>
Čitateľný	99,30	99,30
Nečitateľný	91,30	91,30

Ked'že trieda artefaktov je ordinálny príznak, má zmysel pozrieť sa aj na to, o koľko tried sa model pri chybných predikciách mylil. Pri klasifikácii do štyroch tried sa zo všetkých nesprávnych predikcií model zmýlil o jednu triedu pri **95,0 % segmentov** a o dve triedy pri **4,4 % segmentov**. Triedu 1 s triedou 4 zamenil pri predikcii iba v **0,6 % segmentov**. Toto opäť značí, že model je schopný naučiť sa charakteristické vlastnosti jednotlivých tried, avšak triedy je potrebné striktnejšie zadefinovať, aby sa minimalizoval počet segmentov na medzí dvoch tried.

Kvôli využitiu v reálnom čase je doba, za ktorú dokáže výsledný model predikovať triedu jedného segmentu, dôležitá. Predikciu sme vykonali zvlášť pre každý segment z testovacej množiny dát a výsledné časy spriemerovali. Priemerný čas, ktorý model potrebuje na predikciu jedného segmentu, je **48 ms**, pričom tento čas je samozrejme závislý na použitom hardware.

Kapitola 5

Diskusia

Aj keď navrhnutá klasifikácia pohybových artefaktov v rozsahu definovanom zadaním práce funguje, počas návrhu a realizácie riešenia sa nazbieralo veľké množstvo pozorovaní, od ktorých vieme odvodiť možné vylepšenia navrhnutého riešenia. Rozšírenia sa ponúkajú či už v oblasti riadeného experimentu, anotácie dát, alebo skúmania väčšieho množstva architektúr strojového učenia.

Jedným z rozšírení môže byť využitie dát nameraných v teréne, miesto riadeného experimentu. Takto získané dátá budú bližšie reálnemu využitiu a teda aj výsledný model natrénovaný s ich pomocou má potenciál zachytiť problém presnejšie. Významným rozdielom oproti riadenému experimentu je napríklad odev, ktorý majú osoby na sebe. Keďže sa predpokladá využitie riešenia pre zložky IZS, najmä hasičov, tieto osoby budú mať na sebe prevažne ľažký odev, v porovnaní s civilným odevom, aký mali subjekty riadeného experimentu. Ľažký odev v prípade pohybových artefaktov predstavuje ďalší možný zdroj rušenia.

Čo sa týka riadeného experimentu, prirodzeným vylepšením je jeho rozšírenie či už z pohľadu rozmanitosti pohybových aktivít, alebo množstva dát. Množstvo dát je často rozhodujúce pre kvalitu klasifikácie, čo sme pozorovali aj v tejto práci. Prvé modely sme trénovali priebežne na nameraných dátach, keďže neboli všetky anotované naraz, a presnosť klasifikácie narastala spolu s väčším množstvom dát, rovnako narastla aj keď sme použili validačnú množinu na finálne trénovanie modelu. Väčšie množstvo dát by teda mohlo byť prínosom, pričom okrem zvýšenia počtu subjektov experimentu sa množstvo segmentov dá výrazne zvýšiť aj anotáciou cez klzavé okná, čo nás privádza k ďalšej kategórii možných rozšírení navrhnutého riešenia.

Z hľadiska anotácie dátovej sady sa ponúka niekoľko vylepšení, keďže práve segmenty, ktoré sa nachádzali na pomedzí dvoch tried, sa ukázali ako problematické. Dátá je možné anotovať po kratších oknách, aby sa pravdepodobnosť výskytu viacerých kategórií pohybového artefaktu v jednom segmente znížila. Pri dĺžke kratšej ako 1 sekunda by však už nebolo možné zaručiť, aby každý segment obsahoval jeden celý srdečný cyklus. Lepšou možnosťou môže byť anotácia po jednotlivých srdečných cykloch. Toto riešenie je prácne, lebo vyžaduje robustnú detekciu R-vln v zázname a nájdenie riešenia v prípade, že R-vlna nie je z daného úseku rozoznateľná. Kvôli variabilite srdečného cyklu bude navyše potrebné takto získané segmenty prevzorkovať na jednotlnú dĺžku, aby sa dali použiť ako vstupné dátá pre väčšinu modelov umelej inteligencie. Takto zarovnané segmenty môžu byť dobrým základom predikcie v reálnom čase, kedy by sa miera znečistenia segmentu vyhodnocovala po každom srdečnom cykle. Ďalšou možnosťou je anotácia po úsekoch s variabilnou dĺžkou, kedy by sa dátá anotovali označením časti signálu s vybranou

intenzitou rušenia. Takáto anotácia by síce bola najpresnejšia možná, bolo by však treba vyriešiť, ako vhodne vložiť dátu, ktoré nemajú vopred stanovenú dĺžku, na vstup modelu.

Zhodnotenie kvality anotácie je subjektívne a spravidla sa bude lísiť od jednej osoby k druhej, vyššia miera znalosti interpretácie EKG signálu však môže byť výhodou. Vylepšením z hľadiska správnosti môže teda byť anotácia s asistenciou kardiológov, alebo inej osoby školenej na interpretáciu EKG signálu. Tieto osoby by mali vedieť presnejšie posúdiť, aký veľký vplyv môže mať daná miera znečistenia pohybovým artefaktom na získanie potrebných informácií, či prípadnú diagnostiku z EKG záznamu.

Okrem vylepšení týkajúcich sa anotácie dátovej sady, priestor na zlepšenie zostáva aj z hľadiska optimalizácie počtu tried. Prvé pokusy zahrňali zlúčenie prostredných dvoch tried do jednej, keďže sa ukázalo, že je medzi nimi veľký prienik. Presnosť predikcií po zlúčení výrazne stúpla, takže ďalšia optimalizácia počtu tried by mohla viesť k presnejším výsledkom. Skúmané počty tried by záviseli od spôsobu anotácie, jednou z možností, ktorá sa ponúka, je rozlíšenie dvoch druhov segmentov aktuálne patriacich do triedy 4 - srdečný rytmus nečitateľný kvôli superponovanému rušeniu, oproti nečitateľnosti kvôli saturácii signálu.

Ked'že architektúr strojového učenia je v súčasnosti dostupných mnoho, rozsah tejto práce neumožňoval skúmanie všetkých možností. V tejto práci boli testované rôzne hlboké a konvolučné architektúry. Priestor zostáva pre zahrnutie LSTM vrstiev [48], ktoré by mohli byť obzvlášť prínosné pre spracovanie časovej zložky vstupných dát, prípadne pre klasifikáciu pomocou SVM modelov [52][53].

Kapitola 6

Záver

V úvodnej časti práce je spracovaná základná analýza problému, časť o elektrokardiografii pokrýva rôzne druhy elektród a zvodových systémov, so zameraním na terénnu záťažovú elektrokardiografiu. V krátkosti je opísaná aj genéza signálu a fyziologický priebeh EKG, znalosť ktorého je potrebná na determinovanie kvality signálu, predstavené sú aj najčastejšie sa vyskytujúce artefakty v EKG signáli a ich pôvod. Práca ďalej obsahuje rešeršnú časť súčasne dostupných riešení automatickej detekcie pohybových artefaktov v oblasti strojového učenia. Popísané sú vybrané postupy v oblasti hlbokých, konvolučných a rekurentných neurónových sietí a klasifikácia pomocou SVM modelov.

Ďalšou časťou práce je návrh riadeného experimentu, ktorý bol realizovaný na desiatich subjektoch. Zaznamenaných bolo päť rôznych pohybových aktivít - kľud, pohyby hornými končatinami, chôdza, beh a drep. Každá z týchto aktivít bola zaznamenaná troma rôznymi druhmi elektród a to tradičnými Ag/AgCl elektródami, elektródami z chróm-niklovej ocele a textilnými elektródami. Na zaznamenanie dát bol použitý poskytnutý nositeľný snímač EKG, napojený na 1-zvodový systém. Anotácia dátovéj sady bola významnou súčasťou práce, pričom ako výstup vznikol katalóg 4602 anotovaných segmentov o dĺžke 2 sekundy. Nad rámec zadania a za účelom zefektívnenia anotácie dát bolo implementované jednoduché grafické rozhranie, ktoré slúži na prehliadanie a anotáciu jednotlivých EKG segmentov. Vzniknutá dátová sada je navyše verejne dostupná pod GNU GPL 3.0 licenciou.

Prvým výstupom práce je porovnanie vyššie uvedených typov elektród pre účely terénného monitorovania. Najodolnejšie voči pohybovým artefaktom vyšli textilné elektródy z vodivej tkaniny upevnené na hrudnom páse. Až 51,9 % segmentov EKG signálu zaznamenaných pomocou tohto druhu elektród obsahovalo minimálne až žiadne rušenie a iba 3,3 % segmentov bolo nezvláštiteľných s detekciou srdečného rytmu.

Ďalším výstupom práce je návrh konvolučnej neurónovej siete, ktorá je schopná klasifikovať jednotlivé pohybové aktivity s presnosťou 85,67 %. Navrhnutá architektúra bola s menšími úpravami a po vyladení hyperparametrov následne použitá na klasifikáciu pohybových artefaktov. Pri prvotnej definícii obsahujúcej 4 triedy, sme zistili, že prostredne dve majú veľký prienik. Výrazné zlepšenie presnosti sme dosiahli po zlúčení týchto dvoch tried, kedy presnosť klasifikácie na testovacej množine narástla na 87,62 %. Overili sme aj schopnosť modelu odlišiť segmenty s čitateľným a nečitateľným srdečným rytmom, kedy presnosť dosiahla až 98,70 %.

Najväčším problémom sa ukázali byť segmenty, ktoré sa nachádzajú na pomedzí dvoch tried. Toto tvrdenie máme podložené tým, že až v 95 % nesprávne predikovaných segmentov sa model zmýlil práve o jednu triedu. Pre budúcu optimalizáciu riešenia vidíme niekoľko možných postupov. Jedným by bola precíznejšia anotácia dát, kedy navrhujeme anotáciu po jednom srdečnom cykle, prípadne anotáciu po úsekokach variabilnej dĺžky. Spolupráca s kardiologom by tiež mohla viesť k presnejšej anotácii. Z hľadiska architektúr hlbokeho učenia by mohlo byť prínosné zahrnúť LSTM vrstvy na spracovanie časovej zložky vstupných dát. Čo sa týka implementácie ako relevantnú vidíme možnosť detekcie v reálnom čase, prípadne implementáciu na vstavaných systémoch s obmedzenými zdrojmi.

..... Dodatok A

Informovaný súhlas

Informovaný súhlas

Názov projektu: Automatická detekcia pohybových artefaktov v EKG signáli z nositeľného snímača pomocou metód umelej inteligencie

Riešiteľ: Bc. Veronika Kalousková

Pracovisko: Katedra informačných a komunikačných technológií v medicíne

Cieľom experimentu je vyhotoviť dátovú sadu, ktorá bude použitá na trénovanie a testovanie modelov umelej inteligencie, ktorých úlohou bude detegovať pohybové artefakty s čo najväčšou presnosťou, prípadne klasifikovať konkrétnu pohybovú aktivitu. Na snímanie EKG bude použitý nositeľný snímač napojený pomocou 1-zvodového systému na tri rôzne druhy elektród. Ag/AgCl elektródy, plošné suché elektródy, vyrobené z nerezovej oceli upevnené na hrudnom páse, a textilné elektródy z vodivej tkaniny, tiež upevnené na hrudnom páse.

Experiment bude vykonávaný na niekoľkých dobrovoľníkoch oboch pohlaví nižšie popísaným spôsobom. Vybraný proband bude po príchode na pracovisko požiadaný o vyplnenie dotazníku, v ktorom sa budú dopytovať nasledujúce údaje: Meno, pohlavie, vek, výška, váha, obvod hrudníka. K zmeraniu obvodu hrudníka bude na pracovisku dostupný meter. Probandovi bude následne vysvetlený priebeh a dĺžka merania a zároveň bude poučený, že meranie môže kedykoľvek ukončiť. Proband bude informovaný o možnosti odmietnuť vykonávanie úkonu v prípade, že bude pre neho daný úkon príliš náročný. Taktiež môže proband z akéhokoľvek dôvodu svoju účasť na experimente ukončiť. Účasť na experimente je dobrovoľná, bez nároku na akúkoľvek kompenzáciu.

Probandovi budú najskôr nalepené gélové Ag/AgCl elektródy, potom upevnený hrudný pás s plošnými suchými elektródami a ako posledný pás s textilnými elektródami. S každými elektródami bude požiadany o vykonanie piatich úkonov vo vopred stanovenom poradí, s narastajúcou záťažou, vid' nasledujúca tabuľka.

Pohybová aktivita	Doba merania vo formáte od - do (mm:ss)
Kľud	0:00 - 1:00
Pohyby hornými končatinami	1:00 - 2:00
Chôdza 4 km/h	2:00 - 3:00
Beh 8 km/h	3:00 - 4:00
Drepy	4:00 - 5:00

Experimentu sa zúčastní 10 probandov a časová náročnosť jednej série úkonov s jedným druhom elektród je 5 minút. Po zahrnutí všetkých troch druhov elektród a rézie spojenej s ich vymieňaním je celkový čas na jedného probanda určený ako 30 minút. Použité systémy budú využívané v priestoroch laboratória Katedry informačných a komunikačných technológií v lekárstve.

Gélové elektródy ako aj oba hrudné pásy sa nesmú používať u probandov, ktorých pokožka je na mieste umiestnenia akokoľvek poškodená alebo poranená, prípadne prekrytá obväzovým materiálom. Fáza experimentu, ktorá zahŕňa fyzickú záťaž, vyžaduje vylúčenie osôb, ktoré trpia závažným ochorením dýchacieho alebo kardiovaskulárneho systému. Kvôli pohybu na bežiacom páse je potrebné z experimentu vylúčiť aj osoby trpiace zníženou pohyblivosťou alebo zníženou funkciou rovnovážneho systému, a to aj v prípade zapríčinenia konzumáciou alkoholu, alebo inej omamnej látky. Proband svojim podpisom tohto informovaného súhlasu potvrdzuje, že porozumel vyššie uvedeným vylučovacím kritériám a že ich nespĺňa.

Znížený komfort pre probanda je zapríčinený nalepením gélových elektród a nosením hrudného pásu počas doby trvania experimentu, ako aj fyzickou záťažou vyplývajúcou z jednotlivých úkonov zahrnutých v experimente. V prípade, že proband nespĺňa ani jedno z vylučujúcich kritérií je experiment

v plnej miere bezpečný. Náklady na odškodenie v prípade poškodenia probanda nesie ČVUT FBMI, toto riziko je však minimalizované použitím prístrojov, ktoré využívajú batériové napájanie.

Podpísaním tohto informovaného súhlasu súhlasíte s prístupom riešiteľa k nazbieraným dátam a osobným údajom z dotazníku, bez toho aby došlo k porušeniu dôvernosti informácií o vašej osobe. Z nameraných dát nebudú vyvodzované žiadne závery o zdravotnom stave probanda. Záznamy, podľa ktorých je možné identifikovať probanda, budú uschované ako dôverné dokumenty a nebudú, v miere zaručenej právnymi predpismi, verejne sprístupnené. V prípade, že budú výsledky štúdie publikované, totožnosť probanda nebude zverejnená.

V prípade, že sa vyskytne informácia, ktorá by mohla mať vplyv na rozhodnutie probanda pokračovať v účasti na experimente, proband bude o nej riadne informovaný. Doplňujúce informácie týkajúce sa tejto štúdie a práv probandov je možné získať u vyššie uvedeného riešiteľa. V prípade poškodenia zdravia v súvislosti s účasťou na experimente kontaktujte tiež vyššie uvedeného riešiteľa projektu. Vaša účasť je dobrovoľná, môžete ju odmietnuť, alebo v jej priebehu kedykoľvek odstúpiť, a to bez udania dôvodu a bez akýchkoľvek ďalších finančných, právnych alebo iných následkov.

Prehlásenie:

Svojim podpisom potvrdzujem, že som sa oboznámil/a a porozumel/a všetkým vyššie uvedeným informáciám, a súhlasím tak so svojou účasťou v experimente. Prehlasujem, že nesplňam žiadne vyššie uvedené kritérium, ktoré by neumožňovalo moju účasť v štúdiu.

Meno probanda:

Zodpovedný riešiteľ: Bc. Veronika Kalousková

Dátum narodenia:

Podpis probanda:

Podpis riešiteľa:

V Prahe dňa:

..... **Dodatok B**

Dotazník

Pridelené ID:

Dotazník

Pre potreby výskumného projektu

Automatická detekcia pohybových artefaktov v EKG signáli z nositeľného snímača pomocou metód umelej inteligencie

Poučenie:

Všetky údaje budú použité výhradne pre potreby tohto výskumného projektu a nebudú z nich vyvodzované žiadne závery o vašom zdravotnom stave. Vyplnené osobné údaje nebudú nikde zverejnené a budú s výskumným projektom spojené výhradne prostredníctvom prideleného identifikačného čísla (ID).

Osobné údaje	
Meno:	Priezvisko:
Dátum narodenia: (DD/MM/RR)	Vek:
Pohlavie:	Výška:
Váha:	Obvod hrudníka:
Zdravotný stav (áno / nie) - prípadne uviesť aké	
Ochorenia respiračného a kardiovaskulárneho systému: (napr. astma, srdečné príhody, infarkt atď.)	
Ochorenia pohybového ústrojenstva:	

Prehlasujem a svojim podpisom potvrdzujem, že som všetky uvedené údaje vyplnil/a pravdivo a rozumiem poučeniu v úvode dotazníka.

.....

Miesto a dátum

.....

Podpis probanda

Bibliografia

1. WEINHAUS, Anthony J.; ROBERTS, Kenneth P. Anatomy of the Human Heart. In: *Handbook of Cardiac Anatomy, Physiology, and Devices*. Humana Press, [b.r.], s. 51–79. ISBN 9781588294432. Dostupné z DOI: 10.1007/978-1-59259-835-9_4.
2. *Heart*. 2024. Dostupné tiež z: <https://www.britannica.com/science/heart>.
3. BADA, Viliam. *Základy klinickej elektrokardiografie*. Univerzita Komenského, 2010. ISBN 9788022328210.
4. ROOKE, Thom W; M., D.; SPARKS, Harvey V. The Electrical Activity of the Heart. *Clinical Electrocardiography*. 2021. Dostupné tiež z: <https://api.semanticscholar.org/CorpusID:264706553>.
5. BLAHÚT, Peter. *Akčný Potenciál*. TECHmED, 2017. Dostupné tiež z: <https://www.techmed.sk/akcny-potencial/>.
6. WASILEWSKI, Jarosław; POŁOŃSKI, Lech. An Introduction to ECG Interpretation. In: *ECG Signal Processing, Classification and Interpretation*. Springer London, 2011, s. 1–20. ISBN 9780857298683. Dostupné z DOI: 10.1007/978-0-85729-868-3_1.
7. GARCIA, T.B. *12-lead ECG: The Art of Interpretation*. Jones & Bartlett Learning, 2015. G - Reference,Information and Interdisciplinary Subjects Series. ISBN 9780763773519. Dostupné tiež z: <https://books.google.cz/books?id=svJMEAAQBAJ>.
8. BLAHÚT, Peter. *EKG Elektrody a EKG Zvody*. TECHmED, 2017. Dostupné tiež z: <https://www.techmed.sk/ekg-elektrody-a-ekg-zvody/>.
9. CADOGAN, Mike. *ECG lead positioning*. 2022. Dostupné tiež z: <https://litfl.com/ecg-lead-positioning/>.
10. THAKOR, Nitish V.; WEBSTER, John G. Ground-Free ECG Recording with Two Electrodes. *IEEE Transactions on Biomedical Engineering*. 1980, roč. BME-27, č. 12, s. 699–704. ISSN 1558-2531. Dostupné z DOI: 10.1109/tbme.1980.326595.
11. GARVEY, J. Lee. ECG Techniques and Technologies. *Emergency Medicine Clinics of North America*. 2006, roč. 24, č. 1, s. 209–225. ISSN 0733-8627. Dostupné z DOI: 10.1016/j.emc.2005.08.013.
12. ROUBÍK, Karel. *Fyzikální chemie pro biomedicínské inženýrství*. Nakladatelství ČVUT, 2007. ISBN 9788001037881.
13. MAROZAS, Vaidotas; PETRENAS, Andrius; DAUKANTAS, Saulius; LUKOSEVICIUS, Arunas. A comparison of conductive textile-based and silver/silver chloride gel electrodes in exercise electrocardiogram recordings. *Journal of Electrocardiology*. 2011, roč. 44, č. 2, s. 189–194. ISSN 0022-0736. Dostupné z DOI: 10.1016/j.jelectrocard.2010.12.004.

14. ARQUILLA, Katya; WEBB, Andrea; ANDERSON, Allison. Textile Electrocardiogram (ECG) Electrodes for Wearable Health Monitoring. *Sensors*. 2020, roč. 20, č. 4, s. 1013. ISSN 1424-8220. Dostupné z DOI: 10.3390/s20041013.
15. PANI, Danilo; ACHILLI, Andrea; BONFIGLIO, Annalisa. Survey on Textile Electrode Technologies for Electrocardiographic (ECG) Monitoring, from Metal Wires to Polymers. *Advanced Materials Technologies*. 2018, roč. 3, č. 10. ISSN 2365-709X. Dostupné z DOI: 10.1002/admt.201800008.
16. VOJTECH, Lukas; BORTEL, Radoslav; NERUDA, Marek; KOZAK, Milos. Wearable Textile Electrodes for ECG Measurement. *Advances in Electrical and Electronic Engineering*. 2013, roč. 11, č. 5. ISSN 1336-1376. Dostupné z DOI: 10.15598/aeee.v11i5.889.
17. FOBELETS, Kristel; HAMMOUR, Ghena; THIELEMANS, Kris. Knitted ECG Electrodes in Relaxed Fitting Garments. *IEEE Sensors Journal*. 2023, roč. 23, č. 5, s. 5263–5269. ISSN 2379-9153. Dostupné z DOI: 10.1109/jsen.2023.3236723.
18. XU, Xiaowen; LUO, Meng; HE, Pei; YANG, Junliang. Washable and flexible screen printed graphene electrode on textiles for wearable healthcare monitoring. *Journal of Physics D: Applied Physics*. 2020, roč. 53, č. 12, s. 125402. ISSN 1361-6463. Dostupné z DOI: 10.1088/1361-6463/ab5f4a.
19. PAUL, Gordon; TORAH, Russel; BEEBY, Steve; TUDOR, John. Novel active electrodes for ECG monitoring on woven textiles fabricated by screen and stencil printing. *Sensors and Actuators A: Physical*. 2015, roč. 221, s. 60–66. ISSN 0924-4247. Dostupné z DOI: 10.1016/j.sna.2014.10.030.
20. METSHEIN, Margus. Coupling and electrodes. In: *Bioimpedance and Spectroscopy*. Elsevier, 2021, s. 3–50. Dostupné z DOI: 10.1016/b978-0-12-818614-5.00010-2.
21. FOSTER, Bruce. Springer London, 2007. ISBN 9781846285929. Dostupné z DOI: 10.1007/978-1-84628-610-0.
22. EUAN, Ashley A.; NIEBAUER, Josef. Conquering the ECG. In: *Cardiology Explained*. Remedica, 2004, s. 15–34. Dostupné tiež z: <https://www.ncbi.nlm.nih.gov/books/NBK2214/>.
23. BLAHÚT, Peter. *Určenie elektrickej osi srdca*. TECHmED, 2017. Dostupné tiež z: <https://www.techmed.sk/urcenie-elektrickej-osi-srdca/>.
24. PÉREZ-RIERA, Andrés Ricardo; BARBOSA-BARROS, Raimundo; DAMINELLO-RAIMUNDO, Rodrigo; ABREU, Luiz Carlos de. Main artifacts in electrocardiography. *Annals of Noninvasive Electrocardiology*. 2017, roč. 23, č. 2. ISSN 1542-474X. Dostupné z DOI: 10.1111/anec.12494.
25. LITTMANN, Laszlo. Electrocardiographic artifact. *Journal of Electrocardiology*. 2021, roč. 64, s. 23–29. ISSN 0022-0736. Dostupné z DOI: 10.1016/j.jelectrocard.2020.11.006.
26. *Ecg Artifacts*. 2018. Dostupné tiež z: <http://mauvila.com/>.
27. ROMERO, Francisco Perdigón; ROMAGUERA, Liset Vazquez; VÁZQUEZ-SEISDEDOS, Carlos Román; FILHO, Cícero Ferreira Fernandes Costa; COSTA, Marly Guimarães Fernandes; NETO, João Evangelista. *Baseline wander removal methods for ECG signals: A comparative study*. arXiv, 2018. Dostupné z DOI: 10.48550/ARXIV.1807.11359.
28. KAUR, M.; SINGH, B.; SEEMA. Comparison of different approaches for removal of baseline wander from ECG signal. In: *Proceedings of the International Conference amp; Workshop on Emerging Trends in Technology - ICWET '11*. ACM Press, 2011. ICWET '11. Dostupné z DOI: 10.1145/1980022.1980307.
29. HUHTA, James C.; WEBSTER, John G. 60-Hz Interference in Electrocardiography. *IEEE Transactions on Biomedical Engineering*. 1973, roč. BME-20, č. 2, s. 91–101. ISSN 0018-9294. Dostupné z DOI: 10.1109/tbme.1973.324169.

30. GILANI, Syed Omer; ILYAS, Yasir; JAMIL, Mohsin. Power line noise removal from ECG signal using notch, band stop and adaptive filters. In: *2018 International Conference on Electronics, Information, and Communication (ICEIC)*. IEEE, 2018. Dostupné z DOI: 10.23919/elinfocom.2018.8330569.
31. KIRST, M.; GLAUNER, B.; OTTENBACHER, J. Using DWT for ECG motion artifact reduction with noise-correlating signals. In: *2011 Annual International Conference of the IEEE Engineering in Medicine and Biology Society*. IEEE, 2011. Dostupné z DOI: 10.1109/tembs.2011.6091190.
32. LI, Hongzu; BOULANGER, Pierre. A Survey of Heart Anomaly Detection Using Ambulatory Electrocardiogram (ECG). *Sensors*. 2020, roč. 20, č. 5, s. 1461. ISSN 1424-8220. Dostupné z DOI: 10.3390/s20051461.
33. TONG, D.A.; BARTELS, K.A.; HONEYAGER, K.S. Adaptive reduction of motion artifact in the electrocardiogram. In: *Proceedings of the Second Joint 24th Annual Conference and the Annual Fall Meeting of the Biomedical Engineering Society] [Engineering in Medicine and Biology*. IEEE, [b.r.]. IEMBS-02. Dostupné z DOI: 10.1109/tembs.2002.1106451.
34. MILANESI, M.; MARTINI, N.; VANELLO, N.; POSITANO, V.; SANTARELLI, M. F.; LANDINI, L. Independent component analysis applied to the removal of motion artifacts from electrocardiographic signals. *Medical amp; Biological Engineering amp; Computing*. 2007, roč. 46, č. 3, s. 251–261. ISSN 1741-0444. Dostupné z DOI: 10.1007/s11517-007-0293-8.
35. BHORANIYA, Dixit V; KHER, Rahul K. Motion artifacts extraction using dwt from ambulatory ECG (A-ECG). In: *2014 International Conference on Communication and Signal Processing*. IEEE, 2014. Dostupné z DOI: 10.1109/iccsp.2014.6950112.
36. ZOU, Jinming; HAN, Yi; SO, Sung-Sau. Overview of Artificial Neural Networks. In: *Artificial Neural Networks*. Humana Press, 2008, s. 14–22. ISBN 9781603271011. ISSN 1940-6029. Dostupné z DOI: 10.1007/978-1-60327-101-1_2.
37. YEGNANARAYANA, Bayya. *Artificial neural networks*. PHI Learning Pvt. Ltd., 2009.
38. MEHROTRA, Kishan; MOHAN, Chilukuri K; RANKA, Sanjay. *Elements of artificial neural networks*. MIT press, 1997.
39. DARJI, Sachin T.; KHER, Rahul K. Artificial neural network-based classification of body movements in ambulatory ECG signal. *Journal of Medical Engineering amp; Technology*. 2013, roč. 37, č. 8, s. 535–540. ISSN 1464-522X. Dostupné z DOI: 10.3109/03091902.2013.839750.
40. S. MOHAMED, Ihab. *Detection and Tracking of Pallets using a Laser Rangefinder and Machine Learning Techniques*. 2017. Dostupné z DOI: 10.13140/RG.2.2.30795.69926. Diz. pr.
41. SAKIB, Shadman; AHMED, Nazib; KABIR, Ahmed Jawad; AHMED, Hridon. An Overview of Convolutional Neural Network: Its Architecture and Applications. 2019. Dostupné z DOI: 10.20944/preprints201811.0546.v4.
42. ALOYSIUS, Neena; GEETHA, M. A review on deep convolutional neural networks. In: *2017 International Conference on Communication and Signal Processing (ICCSP)*. IEEE, 2017. Dostupné z DOI: 10.1109/iccsp.2017.8286426.
43. ALBAWI, Saad; MOHAMMED, Tareq Abed; AL-ZAWI, Saad. Understanding of a convolutional neural network. In: *2017 International Conference on Engineering and Technology (ICET)*. 2017, s. 1–6. Dostupné z DOI: 10.1109/ICEngTechnol.2017.8308186.
44. ZHANG, Qifei; FU, Lingjian; GU, Linyue. A Cascaded Convolutional Neural Network for Assessing Signal Quality of Dynamic ECG. *Computational and Mathematical Methods in Medicine*. 2019, roč. 2019, s. 1–12. ISSN 1748-6718. Dostupné z DOI: 10.1155/2019/7095137.

45. STAUDEMAYER, Ralf C.; MORRIS, Eric Rothstein. *Understanding LSTM – a tutorial into Long Short-Term Memory Recurrent Neural Networks*. arXiv, 2019. Dostupné z DOI: 10.48550/ARXIV.1909.09586.
46. HOCHREITER, Sepp. The Vanishing Gradient Problem During Learning Recurrent Neural Nets and Problem Solutions. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*. 1998, roč. 06, č. 02, s. 107–116. ISSN 1793-6411. Dostupné z DOI: 10.1142/s0218488598000094.
47. YU, Yong; SI, Xiaosheng; HU, Changhua; ZHANG, Jianxun. A Review of Recurrent Neural Networks: LSTM Cells and Network Architectures. *Neural Computation*. 2019, roč. 31, č. 7, s. 1235–1270. ISSN 1530-888X. Dostupné z DOI: 10.1162/neco_a_01199.
48. BOLJANIĆ, Tanja; MALEŠEVIĆ, Jovana; KVASCEV, Goran. Deep Neural Network Approach for Artifact Detection in Raw ECG. In: 2022.
49. CRISTIANINI, Nello; SCHOLKOPF, Bernhard. Support Vector Machines and Kernel Methods: The New Generation of Learning Machines. *AI Magazine*. 2002, roč. 23, č. 3, s. 31. Dostupné z DOI: 10.1609/aimag.v23i3.1655.
50. SUTHAHARAN, Shan. Support Vector Machine. In: *Integrated Series in Information Systems*. Springer US, 2016, s. 207–235. ISBN 9781489976413. ISSN 2197-7968. Dostupné z DOI: 10.1007/978-1-4899-7641-3_9.
51. *Lecture 9: SVM*. [B.r.]. Dostupné tiež z: <https://www.cs.cornell.edu/courses/cs4780/2018fa/lectures/lecturenote09.html>.
52. CASTAÑO, F. A.; HERNÁNDEZ, A. M. Motion Artifacts Recognition in Electrocardiographic Signals through Artificial Neural Networks and Support Vector Machines for Personalized Health Monitoring. In: *IFMBE Proceedings*. Springer Singapore, 2017, s. 425–428. ISBN 9789811040863. ISSN 1433-9277. Dostupné z DOI: 10.1007/978-981-10-4086-3_107.
53. KHER, Rahul; PAWAR, Tanmay; THAKAR, Vishvjit; SHAH, Hitesh. Physical activities recognition from ambulatory ECG signals using neuro-fuzzy classifiers and support vector machines. *Journal of Medical Engineering and Technology*. 2015, roč. 39, č. 2, s. 138–152. ISSN 1464-522X. Dostupné z DOI: 10.3109/03091902.2014.998372.
54. GRANDINI, Margherita; BAGLI, Enrico; VISANI, Giorgio. *Metrics for Multi-Class Classification: an Overview*. 2020. Dostupné z arXiv: 2008.05756 [stat.ML].
55. AD8232. 2020. Dostupné tiež z: <https://www.analog.com/media/en/technical-documentation/data-sheets/ad8232.pdf>.
56. *AD8232 Heart ECG Monitor Sensor Module*. 2022.

Obsah príloh

```
data ..... dátá získané v riadenom experimente
  └── ID ..... dátá pre účastníka s identifikátorom ID
      └── labels ..... anotované dátá
LICENSE ..... GNU GPL 3.0 licencia
README.md ..... stručný popis obsahu média
src
  ├── data_labeler ..... zdrojové kódy grafického rozhrania na anotáciu dát
  ├── impl ..... zdrojové kódy implementácie vo formáte Jupyter notebook
  │   └── models ..... výsledné natrénované modely
  └── thesis ..... zdrojová forma práce vo formáte LATEX
text
  ├── dotazník.pdf ..... dotazník k experimentu vo formáte PDF
  ├── informovaný_súhlas.pdf ..... informovaný súhlas k experimentu vo formáte PDF
  └── thesis.pdf ..... text práce vo formáte PDF
```